

Proyecto Integrador de Ciencia de Datos — Fase 1

Inasistencia escolar en la adolescencia paraguaya: magnitud, motivos declarados y brechas territoriales (2022–2024)

Asignatura	Data Science
Fase	1 de 3 — Ponderación 30 %
Integrantes	Matías Morínigo · César Vielman · Iván Paredes
Fecha de entrega	Martes 15 de septiembre
Fuente	Encuesta Permanente de Hogares Continua (EPHC) — Dirección General de Estadística, Encuestas y Censos (DGEEC), Paraguay
Archivos	REG02_EPHC_ANUAL_2022.csv · REG02_EPHC_ANUAL_2023.csv · REG02_EPHC_ANUAL_2024.csv (registro de personas, Sección 4 — Educación)

Por qué se cambió la fuente de datos

La propuesta original de este proyecto preguntaba por los **factores institucionales** (servicios básicos, infraestructura) asociados al **abandono escolar** entre 2015 y 2024, usando registros administrativos del Ministerio de Educación y Ciencias (MEC). Al inventariar los archivos efectivamente disponibles en el portal del MEC se comprobó que:

1. Los datasets de matrícula del MEC cubren un único año lectivo (2023) en el corte descargado.
2. **Ningún dataset del MEC contiene una variable de abandono, deserción o repitencia.**
3. Las variables de servicios básicos existen (`servicios_basicos` de FONACIDE), pero atadas a establecimientos priorizados para inversión, no al universo completo de instituciones ni a una serie temporal comparable.

La **EPHC de la DGEEC**, en cambio, sí trae —todos los años, con metodología estable— la pregunta **ED08** (si la persona asiste actualmente) y, crucialmente, **ED10**: *"¿Por qué no asiste o dejó de asistir?"*, con el motivo declarado por el propio hogar. Es la variable de

abandono que la propuesta original necesitaba y que el MEC no publica en datos abiertos. El costo de este cambio es real y se declara sin rodeos: la unidad de análisis deja de ser el *establecimiento* y pasa a ser la *persona dentro de un hogar*, con un diseño muestral complejo que exige usar el factor de expansión (**FEX**) en todo cálculo descriptivo.

Si en el futuro se consigue el dataset `servicios_basicos` del MEC a nivel de establecimiento y con cobertura nacional, se podría intentar una estimación de disponibilidad de servicios **por departamento** y cruzarla con las tasas de inasistencia calculadas aquí. Esa vía queda anotada como trabajo futuro.

Cómo usar este notebook

1. Los tres CSV (`REG02_EPHC_ANUAL_2022.csv` , `_2023.csv` , `_2024.csv`) van en `data/raw/` , sin modificar.
2. `Kernel → Restart & Run All` . El notebook corre de principio a fin y regenera `data/processed/dataset_fase1.parquet` .
3. Los bloques  **COMPLETAR** exigen redacción propia del grupo: el código produce la evidencia, la interpretación es de ustedes y es lo que se evalúa.
4. Ninguna transformación se hace a mano. Todo queda documentado en la **bitácora de limpieza** (Etapas 3.6).

0. Configuración y reproducibilidad

```
In [1]: # =====
# Imports y configuración global
# =====

import re
import sys
import warnings
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats

warnings.filterwarnings('ignore', category=FutureWarning)

SEMILLA = 42
np.random.seed(SEMILLA)

RAIZ = Path.cwd().parent if Path.cwd().name == 'notebooks' else Path.cwd()
DIR_RAW = RAIZ / 'data' / 'raw'
```

```

DIR_PROC = RAIZ / 'data' / 'processed'
DIR_FIG = RAIZ / 'output' / 'figuras'
DIR_TAB = RAIZ / 'output' / 'tablas'
for _d in (DIR_RAW, DIR_PROC, DIR_FIG, DIR_TAB):
    _d.mkdir(parents=True, exist_ok=True)

sns.set_theme(style='whitegrid', palette='deep')
plt.rcParams.update({'figure.figsize': (10, 5), 'figure.dpi': 110, 'savefig.
                    'savefig.bbox': 'tight', 'axes.titlesize': 13, 'axes.ti
                    'axes.labelsize': 11, 'font.size': 10})
pd.set_option('display.max_columns', 60)
pd.set_option('display.width', 170)
pd.set_option('display.float_format', lambda v: f'{v:,.3f}')

print('Python:', sys.version.split()[0], '| pandas:', pd.__version__, '| num
print('Raíz :', RAIZ)

```

Python: 3.12.4 | pandas: 3.0.5 | numpy: 2.5.3

Raíz : /Users/ivanparedesozuna/Developer/proyecto-ds-inasistencia-py

```

In [2]: # =====
# CONFIG – único lugar a tocar si cambian los archivos o los códigos de vari
# =====

ARCHIVOS_EPHC = {
    2022: 'REG02_EPHC_ANUAL_2022.csv',
    2023: 'REG02_EPHC_ANUAL_2023.csv',
    2024: 'REG02_EPHC_ANUAL_2024.csv',
}

# Columnas del registro de personas (REG02) que se necesitan para este proyec
# El archivo real trae >200 columnas; sólo se cargan las que se van a usar.
COLUMNAS_NECESARIAS = [
    'UPM', 'NVIVI', 'NHOGA', 'AÑO', 'DPT0', 'AREA', 'L02',
    'P02',      # edad
    'P06',      # sexo (1 = Hombre, 6 = Mujer)
    'P04',      # es miembro del hogar
    'ED03',     # ¿asistió alguna vez a enseñanza formal?
    'ED08',     # ¿asiste actualmente? (19 = No asiste)
    'ED09',     # sector de la institución (1 Oficial, 2 Privado, 3 Privado
    'ED10',     # motivo de no asistencia / abandono
    'FEX.2022', # factor de expansión muestral (obligatorio para cualquier
]

# Rango etario de interés: 3er ciclo de la EEB + educación media en Paraguay
# (edad teórica 12 a 17 años). Se declara aquí y se valida empíricamente en
EDAD_MIN, EDAD_MAX = 12, 17

# --- Diccionarios de categorías, tomados del diccionario oficial de variabl
MAPA_AREA = {1: 'Urbana', 6: 'Rural'}
MAPA_SEX0 = {1: 'Hombre', 6: 'Mujer'}
MAPA_ED09_SECTOR = {1: 'Oficial', 2: 'Privado', 3: 'Privado subvencionado',

MAPA_DPT0 = {
    0: 'Capital', 1: 'Concepción', 2: 'San Pedro', 3: 'Cordillera', 4: 'Guai
    5: 'Caaguazú', 6: 'Caazapá', 7: 'Itapúa', 8: 'Misiones', 9: 'Paraguarí',

```

```

10: 'Alto Paraná', 11: 'Central', 12: 'Ñeembucú', 13: 'Amambay', 14: 'Ca
15: 'Presidente Hayes', 16: 'Boquerón', 17: 'Alto Paraguay',
}

MAPA_ED10_MOTIVO = {
    1: 'Sin recursos en el hogar', 2: 'Necesidad de trabajar',
    3: 'Muy costosos materiales y matrículas', 4: 'No tiene edad adecuada',
    5: 'Considera que terminó los estudios', 6: 'No existe institución cerca',
    7: 'Institución cercana muy mala', 8: 'El centro educativo cerró',
    9: 'El docente no asiste con regularidad', 10: 'Institución no ofrece es
    11: 'Requiere educación especial', 12: 'Por enfermedad',
    13: 'Debe hacer labores en el hogar', 14: 'Motivos familiares',
    15: 'No quiere estudiar', 16: 'Asiste a formación profesional/vocacional',
    17: 'Servicio militar', 18: 'Otra razón', 99: 'NR',
}

# ED08: 19 = 'No asiste'; el resto de los códigos (1-18) corresponden a 'Sí',
COD_NO_ASISTE = 19

print('Configuración cargada. Archivos esperados:')
for anio, nombre in ARCHIVOS_EPHC.items():
    ruta = DIR_RAW / nombre
    print(f' {anio}: {nombre:32} {"✅ encontrado" if ruta.exists() else "❌ no encontrado"}')

```

```

Configuración cargada. Archivos esperados:
2022: REG02_EPHC_ANUAL_2022.csv      ✅ encontrado
2023: REG02_EPHC_ANUAL_2023.csv      ✅ encontrado
2024: REG02_EPHC_ANUAL_2024.csv      ✅ encontrado

```

Etapa 1 — Comprensión del problema

1.1. Contexto del problema

La **Dirección General de Estadística, Encuestas y Censos (DGEEC)** de Paraguay releva anualmente la **Encuesta Permanente de Hogares Continua (EPHC)**, una encuesta muestral probabilística a hogares que releva, entre otras dimensiones, la situación educativa de cada miembro del hogar: si asiste actualmente a una institución de enseñanza formal, a qué nivel, en qué sector, y —si no asiste o dejó de asistir— **por qué**. La encuesta usa un diseño muestral complejo con unidades primarias de muestreo (UPM) y un factor de expansión (**FEX**) que permite generalizar los resultados de la muestra a la población total del país.

La **decisión real en juego** es la misma que motivó la propuesta original del proyecto: cómo priorizar la inversión y las políticas de retención escolar. La diferencia es la fuente: en vez de partir del registro administrativo de establecimientos del MEC, este proyecto parte de la **voz del hogar**, que declara directamente por qué un adolescente no está en la escuela. Esa información no la tiene el MEC —un establecimiento no puede reportar

por qué un chico que nunca llegó a inscribirse dejó de estudiar— y es exactamente la que permite distinguir entre causas económicas, familiares, de oferta educativa o de interés personal.

Los usuarios potenciales del análisis son el MEC (para políticas de retención), el Ministerio de Desarrollo Social (para programas de transferencias condicionadas), las gobernaciones y organizaciones que monitorean la equidad educativa territorial.

1.2. Pregunta de investigación

¿En qué medida la zona de residencia (urbana/rural) y el departamento se asocian con la tasa de inasistencia escolar de los adolescentes de 12 a 17 años en Paraguay, y qué motivos declaran los hogares para explicar esa inasistencia, entre 2022 y 2024?

La pregunta cumple los tres criterios exigidos: se responde con **evidencia** (la EPHC, encuesta oficial de la DGEEC) y no con opinión; está **acotada** en tiempo (2022–2024, los tres años con archivo disponible), en edad (12 a 17 años, edad teórica de 3.er ciclo y educación media) y en alcance (zona, departamento y motivo declarado); y **admite respuesta negativa**: es posible que, controlando por departamento, la diferencia urbano/rural no resulte relevante, o que el motivo principal de inasistencia no varíe entre zonas.

1.3. Objetivo general

Analizar la asociación entre la zona de residencia, el departamento y la tasa de inasistencia escolar de los adolescentes de 12 a 17 años en Paraguay entre 2022 y 2024, caracterizando los motivos de inasistencia declarados por los hogares.

1.4. Objetivos específicos

N.º	Objetivo específico	Fase	Sección
OE1	Construir un panel 2022–2024 de personas de 12 a 17 años a partir de los tres registros anuales de la EPHC, con las variables de asistencia, motivo, zona, departamento y factor de expansión correctamente aplicado.	Fase 1	Etapas 2 y 3
OE2	Describir la evolución de la tasa de inasistencia escolar y de sus motivos declarados, por zona, departamento y sexo, entre 2022 y 2024.	Fase 1	Etapas 4 y 5

N.º	Objetivo específico	Fase	Sección
OE3	Determinar si la tasa de inasistencia difiere de forma estadísticamente significativa entre zonas urbana y rural, y entre departamentos, y si el motivo declarado se asocia con la zona.	Fase 2 (inferencial)	Contrastes de hipótesis
OE4	Construir un modelo de clasificación que estime la probabilidad de inasistencia escolar de un adolescente a partir de su zona, departamento, edad y sexo, comparándolo contra una línea base.	Fase 3 (predictiva)	Modelado y evaluación
OE5	Comunicar los hallazgos y sus limitaciones —en particular las propias de trabajar con una encuesta muestral— en términos utilizables por responsables de política educativa.	Cierre	Informe y presentación

OE1 y OE2 se ejecutan íntegramente en esta fase. Las hipótesis preliminares de la sección 5.3 son el insumo directo de OE3 (Fase 2), y la selección de variables de la Etapa 3 define el espacio de atributos de OE4 (Fase 3).

1.5. Justificación de la relevancia

Paraguay ha ampliado su cobertura educativa en las últimas décadas, pero el 3.er ciclo de la escolar básica y la educación media siguen siendo el tramo donde más adolescentes salen del sistema. Las estadísticas agregadas de matrícula no explican **por qué** ocurre esa salida; la EPHC sí lo pregunta directamente. Un análisis que distinga si la inasistencia se debe mayoritariamente a razones económicas, familiares, de oferta educativa insuficiente o de decisión personal tiene una implicancia de política completamente distinta en cada caso: transferencias monetarias, programas de cuidado familiar, ampliación de la oferta escolar, o estrategias de motivación y orientación vocacional, respectivamente.

Además, al tratarse de una encuesta con tres años consecutivos, el proyecto puede documentar si la brecha urbano/rural se mantiene, se amplía o se reduce en el período reciente —algo que un corte único no permite.

1.6. Alcance y limitaciones previstas

Dentro del alcance

- Personas de **12 a 17 años** registradas en el hogar (**P04** = miembro del hogar).
- Período **2022–2024** (los tres años con archivo disponible).
- Variables de **asistencia actual** (**ED08**), **motivo de inasistencia** (**ED10**), **sector** (**ED09**), **zona** (**AREA**), **departamento** (**DPT0**), **sexo** (**P06**) y **edad** (**P02**).
- Todo estadístico descriptivo se calcula **ponderado por el factor de expansión** (**FEX.2022**), como exige el diseño muestral de la encuesta.

Explícitamente fuera

- **Características del establecimiento** (infraestructura, servicios básicos, planta docente): la EPHC no identifica el establecimiento al que asiste o asistía la persona; esa información seguiría el registro administrativo del MEC. No se fuerza un cruce que la propia estructura de los datos no permite.
- **Seguimiento de cohorte.** La EPHC es una encuesta de **corte transversal repetido**, no un panel: no se entrevista a los mismos hogares cada año. "2022–2024" describe tres fotografías comparables, no la trayectoria de las mismas personas en el tiempo.
- **Inferencia causal.** Las asociaciones que se documenten son observacionales; nunca se afirma que la zona o el departamento *causen* la inasistencia, sólo que se *asocian* con ella.
- Niveles educativos fuera del rango 12–17 años (inicial, primaria temprana, superior).

Limitaciones de diseño que se declaran desde ahora

1. **Diseño muestral complejo.** La EPHC tiene estratificación y conglomerados (UPM); los cálculos de este proyecto usan el factor de expansión para las estimaciones puntuales, pero **no** corrigen los errores estándar por el efecto de diseño (eso requeriría el paquete de replicación de la DGEEC, fuera del alcance de la materia). Los intervalos de confianza de la Fase 2 deben leerse con esa salvedad.
2. **Tamaño de submuestra por departamento.** Algunos departamentos pequeños (Alto Paraguay, Boquerón, Ñeembucú) tienen pocas observaciones muestrales; sus estimaciones tendrán mayor error y se señalará explícitamente.
3. **El motivo de inasistencia es autorreportado** por el hogar, no verificado independientemente.
4. **Cobertura territorial incompleta en el Chaco.** Se verifica empíricamente en la Etapa 2.6 si Boquerón y Alto Paraguay están representados en la muestra de los tres años; si no lo están, los resultados de este proyecto no podrán extenderse a esa región y así se declarará en la conclusión.

Etapa 2 — Comprensión y selección de los datos

```
In [3]: # =====
# 2.1 – Inventario de los archivos disponibles
# =====
filas = []
for anio, nombre in ARCHIVOS_EPHC.items():
    ruta = DIR_RAW / nombre
    if not ruta.exists():
        filas.append({'archivo': nombre, 'anio': anio, 'estado': 'NO ENCONTRADO'}
```

```

        continue
    with open(ruta, encoding='utf-8-sig') as f:
        n_cols = len(f.readline().split(';'))
        n_filas = sum(1 for _ in open(ruta, encoding='utf-8-sig')) - 1
        filas.append({'archivo': nombre, 'anio': anio, 'tamano_mb': round(ruta.s
                        'filas': n_filas, 'columnas_totales': n_cols, 'estado': 'C

inventario = pd.DataFrame(filas)
display(inventario)
inventario.to_csv(DIR_TAB / 'inventario_archivos.csv', index=False)

```

	archivo	anio	tamano_mb	filas	columnas_totales	estado
0	REG02_EPHC_ANUAL_2022.csv	2022	29.000	61912	213	OK
1	REG02_EPHC_ANUAL_2023.csv	2023	26.900	58005	213	OK
2	REG02_EPHC_ANUAL_2024.csv	2024	27.100	57744	213	OK

2.1.1. Descripción del inventario

Los tres archivos son el **registro de personas (REG02)** de la EPHC anual, uno por año. Cada fila es una persona dentro de un hogar dentro de una vivienda. Comparten exactamente la misma estructura de columnas (213 en los tres casos), lo que permite concatenarlos directamente en un panel sin necesidad de mapear nombres de campo entre años —a diferencia de lo que suele ocurrir con fuentes administrativas.

Archivo	Año	Contenido	Unidad de análisis	Clave
REG02_EPHC_ANUAL_2022.csv	2022	Registro de personas, todas las secciones (incl. Educación)	persona	UPM + NVIVI + NHOGA + L02
REG02_EPHC_ANUAL_2023.csv	2023	ídem	persona	ídem
REG02_EPHC_ANUAL_2024.csv	2024	ídem	persona	ídem

```

In [4]: # =====
# 2.2 – Carga de los archivos
# =====
# ⚠ Detalle crítico de formato: el archivo usa ';' como separador de columnas
# y ',' como separador DECIMAL (formato numérico latinoamericano). Si se ignora
# el parámetro decimal=',', el factor de expansión FEX se lee como texto y
# cualquier .sum() posterior concatena strings en vez de sumar números,
# produciendo un resultado sin sentido y sin ningún error visible.

tablas_anuales = {}
for anio, nombre in ARCHIVOS_EPHC.items():

```

```

ruta = DIR_RAW / nombre
df_anio = pd.read_csv(ruta, sep=';', encoding='utf-8-sig', decimal=',',
                      usecols=lambda c: c in COLUMNAS_NECESARIAS, low_memory=False)
df_anio['anio_encuesta'] = anio # se usa el año de archivo como ancla
tablas_anuales[anio] = df_anio
print(f'{nombre:32} -> {df_anio.shape[0]:>7,} filas × {df_anio.shape[1]} columnas'
      f'FEX dtype: {df_anio["FEX.2022"].dtype}')

crudo = pd.concat(tablas_anuales.values(), ignore_index=True)
print(f'\nPanel unificado 2022–2024: {crudo.shape[0]:>7,} filas × {crudo.shape[1]} columnas'
      f'FEX dtype: {crudo["FEX.2022"].dtype}')
crudo.head()

```

```

REG02_EPHC_ANUAL_2022.csv -> 61,912 filas × 16 columnas FEX dtype: float64
REG02_EPHC_ANUAL_2023.csv -> 58,005 filas × 16 columnas FEX dtype: float64
REG02_EPHC_ANUAL_2024.csv -> 57,744 filas × 16 columnas FEX dtype: float64

```

Panel unificado 2022–2024: 177,661 filas × 16 columnas

```

Out[4]:
   UPM  NVIVI  NHOGA  AÑO  DPTO  AREA  L02  P02  P04  P06  ED03  ED08  EDI
0    14     10      1  2022     0     1     1   74     1     6     1     0
1    14     10      1  2022     0     1     2   18     1     6     1     3
2    14     20      1  2022     0     1     1   56     1     1     1     0
3    14     20      1  2022     0     1     2   20     1     1     1    16
4    14     22      1  2022     0     1     1   69     1     6     1     0

```

```

In [5]: # =====
# 2.3 – Diccionario de datos (reconstruido por el grupo)
# =====
def diccionario_datos(df: pd.DataFrame, max_cat: int = 6) -> pd.DataFrame:
    filas = []
    for col in df.columns:
        s, nn = df[col], df[col].dropna()
        if pd.api.types.is_numeric_dtype(s) and nn.nunique() > max_cat:
            rango = f'[{nn.min():,.2f} – {nn.max():,.2f}]' if len(nn) else ''
        else:
            cats = nn.astype(str).value_counts().index[:max_cat].tolist()
            extra = '' if nn.nunique() <= max_cat else f' ... (+{nn.nunique() - max_cat} más)'
            rango = ', '.join(cats) + extra
        filas.append({'campo': col, 'tipo_detectado': str(s.dtype), 'tipo_correcto': s.dtype,
                     'descripcion': '', 'unidad': '', 'n_unicos': s.nunique(),
                     'rango_o_categorias': rango, 'pct_faltantes': round(100 * nn.isna().sum() / len(s))})
    return pd.DataFrame(filas)

def completar_diccionario(dicc: pd.DataFrame, meta: dict) -> pd.DataFrame:
    """Rellena tipo_correcto, descripcion y unidad a partir del diccionario"""
    out = dicc.copy()
    for campo, (tipo, desc, unidad) in meta.items():
        mask = out['campo'] == campo
        out.loc[mask, 'tipo_correcto'] = tipo
        out.loc[mask, 'descripcion'] = desc
        out.loc[mask, 'unidad'] = unidad
    return out

```

```
        out.loc[mask, 'tipo_correcto'] = tipo
        out.loc[mask, 'descripcion'] = desc
        out.loc[mask, 'unidad'] = unidad
    return out
```

```
META_ORIGINAL = {'UPM': ('entero', 'Unidad primaria de muestreo del diseño c
```

```
dicc_original = completar_diccionario(diccionario_datos(crudo), META_ORIGINA
dicc_original.to_csv(DIR_TAB / 'diccionario_datos_original.csv', index=False
display(dicc_original)
print('Diccionario original completado con tipo, descripción y unidad (refer
```

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos	ra
0	UPM	int64	entero	Unidad primaria de muestreo del diseño de la EPHC	código	1788	[
1	NVIVI	int64	entero	Número de vivienda dentro de la UPM	código	151	
2	NHOGA	int64	entero	Número de hogar dentro de la vivienda	código	3	
3	AÑO	int64	entero	Año calendario de la ronda de la encuesta (cam...	año	3	
4	DPTO	int64	categórica ordinal (código)	Departamento de residencia (código DGEEC 0–15)	código	16	
5	AREA	int64	categórica (código)	Zona de residencia: 1 urbana, 6 rural	código	2	
6	L02	int64	entero	Número de línea / persona dentro del hogar	código	27	
7	P02	int64	entero	Edad en años cumplidos	años	107	
8	P04	int64	categórica (código)	Relación con el hogar (filtro: miembro del hogar)	código	1	
9	P06	int64	categórica (código)	Sexo: 1 hombre, 6 mujer	código	2	
10	ED03	str	categórica (código)	¿Sabe leer y escribir?	código	4	
11	ED08	str	categórica (código)	Nivel/modalidad al que asiste; 19 = no asiste	código	21	
12	ED09	str	categórica (código)	Sector de la institución (oficial, privado, su...	código	5	
13	ED10	str	categórica (código)	Motivo de no asistir o de haber dejado de asistir	código	20	

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos	ra
14	FEX.2022	float64	continuo	Factor de expansión muestral (personas represe...	personas	35603	
15	anio_encuesta	int64	entero	Año de la ronda, reconstruido al concatenar lo...	año	3	

Diccionario original completado con tipo, descripción y unidad (referencia: diccionario_EPHC_ANUAL_2023.xls).

```
In [6]: # =====
# 2.4 – Unidad de análisis y clave: verificación EMPÍRICA de unicidad
# =====
CLAVE_PERSONA = ['UPM', 'NVIVI', 'NHOGA', 'L02', 'anio_encuesta']

dup = int(crudo.duplicated(subset=CLAVE_PERSONA).sum())
print(f'Clave candidata: {CLAVE_PERSONA}')
print(f'Filas totales           : {len(crudo):,}')
print(f'Combinaciones únicas de clave: {crudo[CLAVE_PERSONA].drop_duplicates}')
print(f'Filas duplicadas por esa clave: {dup:,}')
print(f'¿Es clave primaria dentro de cada año? {"✅ Sí" if dup == 0 else "❌ No"}')

# La unidad de análisis declarada en la Etapa 1.6 es la persona-año.
print('\nUnidad de análisis adoptada: PERSONA dentro de un HOGAR, observada
      '(corte transversal repetido, no panel de las mismas personas).')
```

Clave candidata: ['UPM', 'NVIVI', 'NHOGA', 'L02', 'anio_encuesta']
Filas totales : 177,661
Combinaciones únicas de clave: 177,661
Filas duplicadas por esa clave: 0
¿Es clave primaria dentro de cada año? ✅ Sí

Unidad de análisis adoptada: PERSONA dentro de un HOGAR, observada en un AÑO de encuesta (corte transversal repetido, no panel de las mismas personas).

```
In [7]: # =====
# 2.5 – Perfilado inicial
# =====
print(f'Dimensiones: {crudo.shape[0]:,} filas × {crudo.shape[1]} columnas')
print(f'Memoria      : {crudo.memory_usage(deep=True).sum()/1024**2:,.1f} MB\r')

perfil = pd.DataFrame({
    'tipo_detectado': crudo.dtypes.astype(str),
    'n_unicos': crudo.nunique(dropna=True),
    'faltantes_%': (100*crudo.isna().mean()).round(2),
}).sort_values('faltantes_%', ascending=False)
display(perfil)

print('Distribución de edad (P02):')
display(crudo.P02.describe(percentiles=[.05, .25, .5, .75, .95]))
```

```
print('\nValores observados de ED08 (asistencia) – códigos crudos:')
print(crudo.ED08.value_counts(dropna=False).sort_index())
```

Dimensiones: 177,661 filas × 16 columnas

Memoria : 22.5 MB

	tipo_detectado	n_unicos	faltantes_%
UPM	int64	1788	0.000
NVIVI	int64	151	0.000
NHOGA	int64	3	0.000
AÑO	int64	3	0.000
DPTO	int64	16	0.000
AREA	int64	2	0.000
L02	int64	27	0.000
P02	int64	107	0.000
P04	int64	1	0.000
P06	int64	2	0.000
ED03	str	4	0.000
ED08	str	21	0.000
ED09	str	5	0.000
ED10	str	20	0.000
FEX.2022	float64	35603	0.000
anio_encuesta	int64	3	0.000

Distribución de edad (P02):

```
count    177,661.000
mean       32.673
std        21.891
min         0.000
5%         3.000
25%        14.000
50%        30.000
75%        49.000
95%        72.000
max       106.000
```

Name: P02, dtype: float64

Valores observados de ED08 (asistencia) – códigos crudos:

ED08

	54787
1	5484
10	32
11	31
12	327
13	548
14	2
15	68
16	7628
17	48
18	1051
19	70889
2	28516
3	6323
4	1306
5	12
6	200
7	341
8	1
9	1
99	66

Name: count, dtype: int64

```
In [8]: # =====
# 2.6 – Evaluación de calidad
# =====

chequeos = []
chequeos.append(('Compleitud global', f'{100*(1-crudo.isna().mean().mean())}')
chequeos.append(('Cobertura temporal', f'{sorted(crudo.anio_encuesta.unique())}')
chequeos.append(('Filas duplicadas exactas', f'{crudo.duplicated().sum():,}')
chequeos.append(('Edad fuera de rango plausible (< 0 o > 110)',
                  f'{int(((crudo.P02 < 0) | (crudo.P02 > 110)).sum()):,}')
chequeos.append(('Población total ponderada por año (FEX)',
                  crudo.groupby('anio_encuesta')['FEX.2022'].sum().round(0).a
chequeos.append(('Códigos de ED08 fuera del diccionario oficial (1-19, 99, b
                  sorted(set(crudo.ED08.dropna().unique()) - set(range(1, 20)

# --- Cobertura territorial: ¿aparecen los 17 departamentos + Capital? ----
dptos_observados = sorted(int(d) for d in crudo.DPT0.dropna().unique())
dptos_esperados = set(range(0, 18))
dptos_ausentes = sorted(dptos_esperados - set(dptos_observados))
chequeos.append(('Departamentos observados en la muestra (códigos)', dptos_c
chequeos.append(('Departamentos NUNCA muestreados en 2022-2024', dptos_auser
display(pd.DataFrame(chequeos, columns=['Chequeo', 'Resultado']))

if dptos_ausentes:
    nombres_ausentes = [MAPA_DPT0.get(d, d) for d in dptos_ausentes]
    print(f'\n⚠ {nombres_ausentes} no aparecen en NINGUNO de los tres años
    print('    Esto es sistemático, no un error de cruce: la EPHC no releva
    print('    con la periodicidad y desagregación que sí tiene el resto del
    print('    límite de cobertura territorial en la Etapa 1.6 y en la concl
    print('    resultado de este proyecto puede extenderse a la región del C
```

	Chequeo	Resultado
0	Compleitud global	100.00 % de celdas informadas
1	Cobertura temporal	[np.int64(2022), np.int64(2023), np.int64(2024)]
2	Filas duplicadas exactas	0
3	Edad fuera de rango plausible (< 0 o > 110)	0
4	Población total ponderada por año (FEX)	{2022: 5838780, 2023: 5885678, 2024: 5932576}
5	Códigos de ED08 fuera del diccionario oficial ...	[, 1, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19,...
6	Departamentos observados en la muestra (códigos)	[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13,...
7	Departamentos NUNCA muestreados en 2022-2024	[16, 17]

⚠ ['Boquerón', 'Alto Paraguay'] no aparecen en NINGUNO de los tres años. Esto es sistemático, no un error de cruce: la EPHC no releva esos departamentos con la periodicidad y desagregación que sí tiene el resto del país. Se declara como límite de cobertura territorial en la Etapa 1.6 y en la conclusión de la Fase 1: ningún resultado de este proyecto puede extenderse a la región del Chaco central/norte.

2.7. Evaluación de calidad — lectura

Compleitud. El registro de personas está prácticamente completo en las variables de identificación, zona y departamento; los códigos en blanco de ED08 / ED09 / ED10 no son datos faltantes en sentido estricto, sino personas **fuera del universo de la pregunta** (por ejemplo, adultos a quienes no corresponde preguntarles si asisten a educación media). Ese universo se delimita en la Etapa 3 filtrando por edad.

Consistencia. La estructura de columnas es idéntica en los tres años, lo que evita el problema típico de fuentes administrativas (nombres de campo que cambian entre períodos). El punto de fricción real fue de **formato**: el separador decimal en coma exige `decimal=','` al leer, verificado en la Etapa 2.2.

Exactitud aparente. La suma del factor de expansión por año debe aproximarse a la población total de Paraguay (del orden de 6-7 millones); si ese número no aparece en el orden de magnitud correcto, es señal de que el factor se está leyendo mal (ver nota de la Etapa 2.2).

Actualidad. Los tres años están completos y son los más recientes publicados por la DGEEC al momento de la descarga.

Trazabilidad. La fuente (DGEEC, EPHC anual) y el diccionario oficial de variables permiten auditar cada código contra la documentación metodológica publicada.

2.8. Selección justificada

Elemento	Decisión	Justificación	Objetivo vinculado
Sección Educación (ED01 – ED11GH1A)	Se conserva parcialmente (ED03 , ED08 , ED09 , ED10)	Son las variables de asistencia, sector y motivo que responden la pregunta	OE1–OE4
ED0504 (nivel más alto aprobado) y ED06C (título obtenido)	Se descarta	Describen la trayectoria educativa completa, no la asistencia actual ni el motivo de inasistencia	—
ED11F1 , ED11GH1 (merienda/almuerzo escolar)	Se descarta de esta fase	Es un programa social distinto al fenómeno de inasistencia; podría explorarse como variable de control en la Fase 3	(posible OE4)
Todas las secciones de empleo, salud e ingresos (A01 – C...)	Se descarta	Fuera del alcance declarado en la Etapa 1.6; ninguna hipótesis del proyecto las requiere	—
Personas fuera de 12–17 años	Se descarta para el análisis principal	La pregunta está acotada a esa edad teórica (Etapa 1.6); se conserva el archivo completo por si se decide ampliar el rango más adelante	OE1–OE4

2.9. Documentación de la fuente

Ítem	Valor
Fuente	Dirección General de Estadística, Encuestas y Censos (DGEEC), Paraguay
Encuesta	Encuesta Permanente de Hogares Continua (EPHC), rondas anuales 2022, 2023 y 2024
Archivos	REG02_EPHC_ANUAL_2022.csv , REG02_EPHC_ANUAL_2023.csv , REG02_EPHC_ANUAL_2024.csv
Diccionario de variables	diccionario_EPHC_ANUAL_2023.xls (hoja EPHC 2023)
Licencia	Microdatos de uso público de la DGEEC
Unidad de medida del factor de expansión	Personas representadas en la población (FEX.2022)

Ítem	Valor
Responsable de la descarga	Iván Paredes (archivos colocados en <code>data/raw/</code> por el grupo)
Fecha de descarga	12 de septiembre de 2026

Etaapa 3 — Limpieza y transformación

Regla no negociable: toda transformación es reproducible por código desde los archivos originales. Nada se edita a mano. Cada decisión queda registrada en la bitácora (sección 3.6).

```
In [9]: # =====
# Bitácora de limpieza
# =====
class Bitacora:
    def __init__(self):
        self.registros = []
    def anotar(self, etapa, decision, afectados, fundamento, antes=None, des
        self.registros.append({'n': len(self.registros)+1, 'etapa': etapa, '
                                'registros_afectados': afectados, 'filas_ante
                                'filas_despues': despues, 'fundamento': funda
        print(f'[{len(self.registros):02d}] {etapa} - {decision} ({afectados
    def tabla(self):
        return pd.DataFrame(self.registros)

bitacora = Bitacora()
df = crudo.copy()
FILAS_INICIALES = len(df)
print(f'Punto de partida: {FILAS_INICIALES:,} filas (todas las personas, toc
```

Punto de partida: 177,661 filas (todas las personas, todas las edades, 2022–2024)

```
In [10]: # =====
# 3.1 – Normalización de tipos y de categorías
# =====

# Renombrado a nombres de trabajo legibles (se conserva la equivalencia en e
df = df.rename(columns={
    'AÑO': 'anio_dato', 'DPT0': 'cod_departamento', 'AREA': 'cod_zona', 'P02
    'P06': 'cod_sexo', 'ED08': 'cod_asistencia', 'ED09': 'cod_sector', 'ED10
    'FEX.2022': 'factor_expansion',
})
bitacora.anotar('3.1 Tipos', 'Renombrado de columnas a nombres de trabajo le
                'Los códigos crudos (P02, ED08, ...) no son autoexplicativos;

for col in ['cod_departamento', 'cod_zona', 'cod_sexo', 'cod_asistencia', 'c
    df[col] = pd.to_numeric(df[col], errors='coerce')
```

```

df['zona'] = df.cod_zona.map(MAPA_AREA)
df['sexo'] = df.cod_sexo.map(MAPA_SEX0)
df['departamento'] = df.cod_departamento.map(MAPA_DPT0)
df['sector'] = df.cod_sector.map(MAPA_ED09_SECTOR)
df['motivo_inasistencia'] = df.cod_motivo.map(MAPA_ED10_MOTIVO)
bitacora.anoar('3.1 Tipos', 'Mapeo de códigos numéricos a etiquetas legibles (zona, sexo, departamento, sector, motivo) (177,661)')

n_sin_dpto = int(df.departamento.isna().sum())
if n_sin_dpto:
    print(f'⚠️ {n_sin_dpto} filas con código de departamento fuera de 0-17 (')

display(df[['anio_encuesta', 'edad', 'zona', 'sexo', 'departamento', 'sector', 'motivo_inasistencia']])

```

[01] 3.1 Tipos – Renombrado de columnas a nombres de trabajo legibles (16)
 [02] 3.1 Tipos – Mapeo de códigos numéricos a etiquetas legibles (zona, sexo, departamento, sector, motivo) (177,661)

	anio_encuesta	edad	zona	sexo	departamento	sector	cod_asistencia
0	2022	74	Urbana	Mujer	Capital	NaN	NaN
1	2022	18	Urbana	Mujer	Capital	Oficial	3.000
2	2022	56	Urbana	Hombre	Capital	NaN	NaN
3	2022	20	Urbana	Hombre	Capital	Privado	16.000
4	2022	69	Urbana	Mujer	Capital	NaN	NaN

```

In [11]: # =====
# 3.2 – Delimitación del universo de análisis: personas de 12 a 17 años
# =====
antes = len(df)
n_fuera_edad = int((~df.edad.between(EDAD_MIN, EDAD_MAX)).sum())
panel = df[df.edad.between(EDAD_MIN, EDAD_MAX)].copy()
bitacora.anoar('3.2 Universo', f'Filtro a edad {EDAD_MIN}--{EDAD_MAX} años (')
                n_fuera_edad,
                'La pregunta de investigación está acotada a la edad teórica')
                'incluir otras edades mezclaría fenómenos distintos (deserción)')
                antes, len(panel))

n_dpto_faltante = int(panel.departamento.isna().sum())
if n_dpto_faltante:
    antes = len(panel)
    panel = panel[panel.departamento.notna()].copy()
    bitacora.anoar('3.2 Universo', 'Eliminación de filas sin departamento m')
                'Código de departamento fuera del rango documentado (0-17)')
                antes, len(panel))

print(f'\nUniverso de análisis (12-17 años, 2022-2024): {len(panel):,} perso')
print(f'Población representada (ponderada): {panel.factor_expansion.sum():,} ')

```

[03] 3.2 Universo – Filtro a edad 12–17 años (universo declarado en Etapa 1.6) (159,103)

Universo de análisis (12–17 años, 2022–2024): 18,558 personas encuestadas
Población representada (ponderada): 1,846,521 personas

```
In [12]: # =====
# 3.3 – Construcción de la variable de asistencia y de inasistencia
# =====
panel['asiste_actualmente'] = (panel.cod_asistencia != COD_NO_ASISTE).astype(int)
panel['no_asiste'] = 1 - panel['asiste_actualmente']
bitacora.anostrar('3.3 Derivadas', f'Creación de «asiste_actualmente» / «no_asiste» a partir del código 19 (18,558)')
len(panel), 'ED08 trae 19 códigos de nivel/modalidad para que sea binario porque la pregunta de investigación es sobre inasistencia'

# El motivo (ED10) sólo tiene sentido para quienes no asisten; se documenta con motivo
con_motivo = panel[panel.no_asiste == 1]
n_motivo_valido = int(con_motivo.motivo_inasistencia.notna().sum())
print(f'Personas que NO asisten (muestra): {len(con_motivo):,}')
print(f'De ellas, con motivo válido registrado: {n_motivo_valido:,} '
      f'({100*n_motivo_valido/max(len(con_motivo),1):.1f} %)')
```

[04] 3.3 Derivadas – Creación de «asiste_actualmente» / «no_asiste» a partir del código 19 (18,558)

Personas que NO asisten (muestra): 1,504

De ellas, con motivo válido registrado: 1,504 (100.0 %)

```
In [13]: # =====
# 3.4 – Valores atípicos e inconsistencias
# =====
# El factor de expansión debe ser positivo; un valor negativo o cero sería un error
incons = [
    ('factor_expansion <= 0', int((panel.factor_expansion <= 0).sum())),
    ('edad fuera de 12-17 (control post-filtro)', int((~panel.edad.between(12, 17)).sum())),
    ('cod_sexo fuera de {1, 6}', int((~panel.cod_sexo.isin([1, 6])).sum())),
]
display(pd.DataFrame(incons, columns=['Chequeo', 'Registros']))

# Distribución del factor de expansión (para detectar valores extremos que causen sesgo)
display(panel.factor_expansion.describe(percentiles=[.01, .05, .5, .95, .99]))

bitacora.anostrar('3.4 Atípicos', 'Factores de expansión extremos CONSERVADOS')
bitacora.anostrar('3.4 Atípicos', 'Los pesos muestrales grandes son parte del diseño (representación de la población)')
bitacora.anostrar('3.4 Atípicos', 'no son errores de carga y eliminarlos introduciría sesgo, por lo que se conservan')
```

	Chequeo	Registros
0	factor_expansion <= 0	0
1	edad fuera de 12-17 (control post-filtro)	0
2	cod_sexo fuera de {1, 6}	0

```
count    18,558.000
mean      99.500
std       62.889
min       11.183
1%        25.090
5%        33.169
50%       85.672
95%      214.322
99%      314.228
max       985.537
```

Name: factor_expansion, dtype: float64

[05] 3.4 Atípicos – Factores de expansión extremos CONSERVADOS (0)

```
In [14]: # =====
# 3.5 – Funciones de estadística ponderada (usadas en toda la Etapa 4 y 5)
# =====

def tasa_ponderada(df, col_indicador, col_peso='factor_expansion') -> float:
    """% ponderado de un indicador 0/1, expandido a la población representada"""
    return 100 * np.average(df[col_indicador], weights=df[col_peso])

def tabla_tasas_por_grupo(df, col_grupo, col_indicador='no_asiste', col_peso='factor_expansion'):
    def _agg(g):
        return pd.Series({
            'n_muestral': len(g),
            'poblacion_ponderada': g[col_peso].sum(),
            'tasa_%': tasa_ponderada(g, col_indicador, col_peso),
        })
    return df.groupby(col_grupo).apply(_agg).sort_values('tasa_%', ascending=False)

def tabla_contingencia_ponderada(df, fila, columna, col_peso='factor_expansion'):
    """Tabla de doble entrada con SUMA de pesos (no conteo de filas)."""
    return df.pivot_table(index=fila, columns=columna, values=col_peso, aggfunc='sum')

print('Funciones de estadística ponderada listas: tasa_ponderada(), tabla_tasas_por_grupo(), tabla_contingencia_ponderada()')
print('\nVerificación: tasa nacional de inasistencia (12-17), ponderada, por año de encuesta:')
display(tabla_tasas_por_grupo(panel, 'anio_encuesta').round(2))
```

Funciones de estadística ponderada listas: tasa_ponderada(), tabla_tasas_por_grupo(), tabla_contingencia_ponderada()

Verificación: tasa nacional de inasistencia (12-17), ponderada, por año de encuesta:

	n_muestral	poblacion_ponderada	tasa_%
anio_encuesta			
2022	6,618.000	618,044.980	8.480
2023	6,026.000	614,894.160	7.550
2024	5,914.000	613,581.410	7.410

```

In [15]: # =====
# 3.6 – Bitácora y exportación del dataset final
# =====
tabla_bitacora = bitacora.tabla()
display(tabla_bitacora)
tabla_bitacora.to_csv(DIR_TAB / 'bitacora_limpieza.csv', index=False)

COLS_FINALES = ['anio_encuesta', 'UPM', 'NVIVI', 'NHOGA', 'L02', 'edad', 'se',
                'sector', 'asiste_actualmente', 'no_asiste', 'motivo_inasist
final = panel[COLS_FINALES].copy()

print(f'Filas iniciales (todas las edades, 2022–2024): {FILAS_INICIALES:,}')
print(f'Filas finales (universo 12–17 años)           : {len(final):,}')
print(f'Población representada (ponderada)             : {final.factor_expansi

try:
    ruta = DIR_PROC / 'dataset_fase1.parquet'; final.to_parquet(ruta, index=
except Exception:
    ruta = DIR_PROC / 'dataset_fase1.csv'; final.to_csv(ruta, index=False, e
print('Dataset limpio guardado en:', ruta.relative_to(RAIZ))

META_FINAL = {'anio_encuesta': ('entero', 'Año de la ronda EPHC (2022, 2023

dicc_final = completar_diccionario(diccionario_datos(final), META_FINAL)
dicc_final.to_csv(DIR_TAB / 'diccionario_datos_final.csv', index=False)
display(dicc_final)

```

	n	etapa	decision	registros_afectados	filas_antes	filas_despues
0	1	3.1 Tipos	Renombrado de columnas a nombres de trabajo le...	16	NaN	NaN
1	2	3.1 Tipos	Mapeo de códigos numéricos a etiquetas legible...	177661	NaN	NaN
2	3	3.2 Universo	Filtro a edad 12-17 años (universo declarado e...	159103	177,661.000	18,558.000
3	4	3.3 Derivadas	Creación de «asiste_actualmente» / «no_asiste»...	18558	NaN	NaN
4	5	3.4 Atípicos	Factores de expansión extremos CONSERVADOS	0	NaN	NaN

Filas iniciales (todas las edades, 2022–2024): 177,661
 Filas finales (universo 12–17 años) : 18,558
 Población representada (ponderada) : 1,846,521

Dataset limpio guardado en: data/processed/dataset_fase1.parquet

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos
0	anio_encuesta	int64	entero	Año de la ronda EPHC (2022, 2023 o 2024)	año	3
1	UPM	int64	entero	Unidad primaria de muestreo	código	1773
2	NVIVI	int64	entero	Número de vivienda dentro de la UPM	código	128
3	NHOGA	int64	entero	Número de hogar dentro de la vivienda	código	3
4	L02	int64	entero	Número de línea / persona dentro del hogar	código	20
5	edad	int64	entero	Edad en años cumplidos (universo 12–17)	años	6
6	sexo	str	categoría nominal	Sexo declarado (Hombre / Mujer)	categoría	2
7	zona	str	categoría nominal	Zona de residencia (Urbana / Rural)	categoría	2
8	departamento	str	categoría nominal	Departamento de residencia (16 dptos. relevados)	categoría	16
9	sector	str	categoría nominal	Sector de la institución a la que asiste; nulo...	categoría	4
10	asiste_actualmente	int64	binaria	1 si asiste a educación formal; 0 si no asiste...	0/1	2
11	no_asiste	int64	binaria	Variable objetivo: 1 = no asiste; 0 = asiste	0/1	2

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos
12	motivo_inasistencia	str	categorica nominal	Motivo declarado (ED10); nulo si asiste	categoría	17
13	factor_expansion	float64	continuo	Factor de expansión (FEX.2022); pondera cada e...	personas	11114

Etapas 4 — Análisis univariado y bivariado

Nota metodológica que atraviesa toda esta etapa: por tratarse de una encuesta muestral, todas las frecuencias, tasas y proporciones se calculan **ponderadas por factor_expansion**. Los conteos simples de filas (`n_muestral`) se reportan aparte porque indican la precisión de la estimación, no el tamaño real de la población.

4.1. Univariado — variable numérica (edad)


```
In [16]: # =====
# Estadísticos de la edad (única variable numérica sustantiva del panel)
# =====
def resumen_numerico_ponderado(df, col, peso='factor_expansion'):
    valores, pesos = df[col].values, df[peso].values
    media = np.average(valores, weights=pesos)
    varianza = np.average((valores - media)**2, weights=pesos)
    orden = np.argsort(valores)
    v_ord, p_ord = valores[orden], pesos[orden]
    cum = np.cumsum(p_ord) / p_ord.sum()
    percentil = lambda q: v_ord[np.searchsorted(cum, q)]
    return {
        'n': len(df), 'media_ponderada': media, 'desvio_ponderado': np.sqrt(
            varianza), 'p5': percentil(.05), 'p25': percentil(.25), 'mediana': percentil(.5),
            'p75': percentil(.75), 'p95': percentil(.95), 'min': valores.min(),
            'asimetria_muestral': stats.skew(valores), 'curtosis_muestral': stats.kurtosis(valores)
    }

resumen_edad = resumen_numerico_ponderado(final, 'edad')
display(pd.Series(resumen_edad).to_frame('edad (12-17 años)'))

fig, ax = plt.subplots(figsize=(9, 4.5))
sns.histplot(data=final, x='edad', weights='factor_expansion', bins=6, discrete=True)
ax.set_title('Distribución ponderada de la edad en el universo de análisis (ED10)')
ax.set_xlabel('Edad (años)'); ax.set_ylabel('Población representada (personas)')
```

```
plt.savefig(DIR_FIG / '01_univariado_edad.png'); plt.show()
print('La distribución ponderada es razonablemente uniforme: cada edad simple  
de la población representada (media ponderada 14,5 años). No hay un hueco  
sugiera un problema de muestreo por edad. El único matiz es 2024, con  
a 1.125 en 2022); no altera el perfil agregado 2022–2024.')
```

edad (12-17 años)	
n	18,558.000
media_ponderada	14.485
desvio_ponderado	1.709
p5	12.000
p25	13.000
mediana	14.000
p75	16.000
p95	17.000
min	12.000
max	17.000
asimetria_muestral	0.021
curtosis_muestral	-1.281



La distribución ponderada es razonablemente uniforme: cada edad simple concentra entre 16,2 % y 17,3 % de la población representada (media ponderada 14,5 años). No hay un hueco ni un pico anómalo que sugiera un problema de muestreo por edad. El único matiz es 2024, con menos casos de 17 años (894 frente a 1.125 en 2022); no altera el perfil agregado 2022–2024.

4.2. Univariado — variables categóricas y concentración

```
In [17]: # =====  
# Frecuencias ponderadas y concentración  
# =====  
VARS_CAT = ['zona', 'sexo', 'departamento', 'sector', 'anio_encuesta']  
for c in VARS_CAT:  
    tab = (final.groupby(c)['factor_expansion'].sum().sort_values(ascending=  
    tab_pct = (100 * tab / tab.sum()).round(2)  
    resumen = pd.concat([tab.round(0).rename('poblacion_ponderada'), tab_pct  
    resumen['acumulada_%'] = resumen['%'].cumsum().round(2)  
    print(f'\n=== {c} - {tab.size} categorías ===')  
    display(resumen)
```

=== zona - 2 categorías ===

	poblacion_ponderada	%	acumulada_%
zona			
Urbana	1,079,928.000	58.480	58.480
Rural	766,593.000	41.520	100.000

=== sexo - 2 categorías ===

	poblacion_ponderada	%	acumulada_%
sexo			
Mujer	925,457.000	50.120	50.120
Hombre	921,064.000	49.880	100.000

=== departamento - 16 categorías ===

	poblacion_ponderada	%	acumulada_%
departamento			
Central	531,119.000	28.760	28.760
Alto Paraná	225,971.000	12.240	41.000
Caaguazú	166,247.000	9.000	50.000
Itapúa	152,608.000	8.260	58.260
San Pedro	126,576.000	6.850	65.110
Capital	110,571.000	5.990	71.100
Cordillera	84,877.000	4.600	75.700
Concepción	74,906.000	4.060	79.760
Paraguarí	63,844.000	3.460	83.220
Canindeyú	62,577.000	3.390	86.610
Guairá	61,799.000	3.350	89.960
Caazapá	58,313.000	3.160	93.120
Amambay	46,911.000	2.540	95.660
Misiones	32,614.000	1.770	97.430
Presidente Hayes	28,091.000	1.520	98.950
Ñeembucú	19,498.000	1.060	100.010


=== sector – 4 categorías ===

	poblacion_ponderada	%	acumulada_%
sector			
Oficial	1,396,593.000	82.310	82.310
Privado	178,048.000	10.490	92.800
Privado subvencionado	121,651.000	7.170	99.970
NR	511.000	0.030	100.000

=== anio_encuesta – 3 categorías ===

	poblacion_ponderada	%	acumulada_%
anio_encuesta			
2022	618,045.000	33.470	33.470
2023	614,894.000	33.300	66.770
2024	613,581.000	33.230	100.000

```
In [18]: # =====
# Gráfico univariado de zona y sector (ponderados)
# =====
fig, axes = plt.subplots(1, 2, figsize=(12, 4.8))
for ax, col in zip(axes, ['zona', 'sector']):
    tab = final.groupby(col)['factor_expansion'].sum().sort_values(ascending=True)
    ax.bar(tab.index.astype(str), tab.values, color='#4c72b0')
    ax.set_title(f'Población de 12-17 años por {col} (ponderada)')
    ax.set_ylabel('Personas representadas'); ax.tick_params(axis='x', rotation=45)
plt.tight_layout(); plt.savefig(DIR_FIG / '02_univariado_categoricas.png');
```



4.3. Bivariado — la variable central: tasa de inasistencia por grupo

```
In [19]: # =====
# Tasa de inasistencia ponderada por zona, sexo y año
# =====
for col in ['zona', 'sexo', 'anio_encuesta']:
    print(f'\n=== Tasa de inasistencia (12-17) según {col} ===')
    display(tabla_tasas_por_grupo(final, col).round(2))
```

=== Tasa de inasistencia (12-17) según zona ===

	n_muestral	poblacion_ponderada	tasa_%
zona			
Rural	8,628.000	766,592.800	11.690
Urbana	9,930.000	1,079,927.750	5.060

=== Tasa de inasistencia (12-17) según sexo ===

	n_muestral	poblacion_ponderada	tasa_%
sexo			
Hombre	9,452.000	921,063.530	8.810
Mujer	9,106.000	925,457.010	6.820

=== Tasa de inasistencia (12-17) según anio_encuesta ===

	n_muestral	poblacion_ponderada	tasa_%
anio_encuesta			
2022	6,618.000	618,044.980	8.480
2023	6,026.000	614,894.160	7.550
2024	5,914.000	613,581.410	7.410


```
In [20]: # =====
# Bivariado numérica-categórica: ¿la edad se asocia con la inasistencia?
# =====
print('Edad media ponderada, según asiste / no asiste:')
display(final.groupby('no_asiste').apply(
    lambda g: pd.Series({'edad_media_pond': np.average(g.edad, weights=g.fac
    ))

fig, ax = plt.subplots(figsize=(9, 5))
sns.violinplot(data=final, x='no_asiste', y='edad', ax=ax, inner='quartile',
ax.set_xticklabels(['Asiste', 'No asiste'])
ax.set_title('Distribución de edad según condición de asistencia')
ax.set_xlabel(''); ax.set_ylabel('Edad (años)')
plt.savefig(DIR_FIG / '03_edad_por_asistencia.png'); plt.show()
print('La inasistencia se concentra en las edades altas: la tasa ponderada p
    '19,1 % a los 17. Quienes no asisten tienen en promedio 15,8 años frer
    'El patrón es coherente con la transición al 3.er ciclo y, sobre todo,
```

Edad media ponderada, según asiste / no asiste:

	edad_media_pond	n
no_asiste		
0	14.376	17,054.000
1	15.767	1,504.000

```
/var/folders/lp/flhffk1951v91kr4yx185z3m0000gn/T/ipykernel_38871/3019359652.
py:11: UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator. Otherwise, ticks m
ay be mislabeled.
    ax.set_xticklabels(['Asiste', 'No asiste'])
```



La inasistencia se concentra en las edades altas: la tasa ponderada pasa de 1,3 % a los 12 años a 19,1 % a los 17. Quienes no asisten tienen en promedio 15,8 años frente a 14,4 de quienes asisten. El patrón es coherente con la transición al 3.er ciclo y, sobre todo, a la educación media.

4.4. Bivariado — categórica frente a categórica (tablas de contingencia ponderadas)

```
In [21]: # =====
# Tabla de contingencia ponderada: zona × sector (entre quienes asisten)
# =====
asisten = final[final.asiste_actualmente == 1]
cont = tabla_contingencia_ponderada(asisten, 'zona', 'sector')
print('--- Población ponderada que asiste, por zona y sector ---'); display(
print('--- % por fila (dentro de cada zona) ---')
display((100 * cont.div(cont.sum(axis=1), axis=0)).round(2))

chi2, p, gl, esp = stats.chi2_contingency(cont)
v = np.sqrt(chi2 / (cont.values.sum() * (min(cont.shape)-1)))
print(f'\nExploratorio (sobre frecuencias ponderadas, no el n muestral real)
      f'χ² = {chi2:,.1f} | p = {p:.4g} | V de Cramér = {v:.3f}')
print('⚠ Este chi-cuadrado usa la población EXPANDIDA como si fuera el tama
      'artificialmente la significancia. Es válido para describir la asociac
      'contraste formal de la Fase 2 deberá ejecutarse sobre el n muestral r

--- Población ponderada que asiste, por zona y sector ---
```

sector	NR	Oficial	Privado	Privado subvencionado
zona				
Rural	0.000	628,922.000	23,190.000	23,536.000
Urbana	511.000	767,671.000	154,858.000	98,115.000

--- % por fila (dentro de cada zona) ---

sector	NR	Oficial	Privado	Privado subvencionado
zona				
Rural	0.000	93.080	3.430	3.480
Urbana	0.050	75.180	15.170	9.610

Exploratorio (sobre frecuencias ponderadas, no el n muestral real): $\chi^2 = 90,797.6$ | $p = 0$ | V de Cramér = 0.231

⚠ Este chi-cuadrado usa la población EXPANDIDA como si fuera el tamaño muestral real, lo que infla artificialmente la significancia. Es válido para describir la asociación (V de Cramér), pero el contraste formal de la Fase 2 deberá ejecutarse sobre el n muestral real o con métodos de encuestas complejas.

```
In [22]: # =====
# Tabla de contingencia ponderada: zona x motivo de inasistencia
# =====
no_asisten = final[final.no_asiste == 1].dropna(subset=['motivo_inasistencia'])
cont_motivo = tabla_contingencia_ponderada(no_asisten, 'motivo_inasistencia')
cont_motivo['total'] = cont_motivo.sum(axis=1)
cont_motivo = cont_motivo.sort_values('total', ascending=False).drop(columns='total')
display(cont_motivo.round(0))
print('\n--- % de cada motivo dentro de cada zona ---')
display((100 * cont_motivo.div(cont_motivo.sum(axis=0), axis=1)).round(1))
```

motivo_inasistencia	zona	Rural	Urbana
Sin recursos en el hogar		24,828.000	15,003.000
No quiere estudiar		18,246.000	13,749.000
Motivos familiares		18,514.000	10,892.000
Necesidad de trabajar		7,973.000	6,463.000
No existe institución cercana		10,059.000	421.000
Requiere educación especial		2,736.000	2,330.000
Por enfermedad		1,998.000	2,481.000
Otra razón		454.000	2,298.000
Considera que terminó los estudios		2,024.000	0.000
Muy costosos materiales y matrículas		1,303.000	237.000
Institución cercana muy mala		660.000	224.000
Institución no ofrece escolaridad completa		473.000	92.000
Asiste a formación profesional/vocacional		59.000	431.000
El docente no asiste con regularidad		147.000	0.000
El centro educativo cerró		105.000	0.000
Debe hacer labores en el hogar		0.000	71.000

--- % de cada motivo dentro de cada zona ---


	zona	Rural	Urbana
motivo_inasistencia			
Sin recursos en el hogar		27.700	27.400
No quiere estudiar		20.400	25.100
Motivos familiares		20.700	19.900
Necesidad de trabajar		8.900	11.800
No existe institución cercana		11.200	0.800
Requiere educación especial		3.100	4.300
Por enfermedad		2.200	4.500
Otra razón		0.500	4.200
Considera que terminó los estudios		2.300	0.000
Muy costosos materiales y matrículas		1.500	0.400
Institución cercana muy mala		0.700	0.400
Institución no ofrece escolaridad completa		0.500	0.200
Asiste a formación profesional/vocacional		0.100	0.800
El docente no asiste con regularidad		0.200	0.000
El centro educativo cerró		0.100	0.000
Debe hacer labores en el hogar		0.000	0.100

4.5. Análisis temporal (2022–2024)

```
In [23]: # =====
# Evolución de la tasa de inasistencia por año y zona
# =====
evo = final.groupby(['anio_encuesta', 'zona']).apply(
    lambda g: tasa_ponderada(g, 'no_asiste')).unstack()
display(evo.round(2))
evo.to_csv(DIR_TAB / 'serie_temporal_tasa_inasistencia.csv')

fig, ax = plt.subplots(figsize=(9, 5))
for col in evo.columns:
    ax.plot(evo.index, evo[col], marker='o', lw=2, label=col)
ax.set_title('Evolución de la tasa de inasistencia escolar (12–17 años) según año de la encuesta')
ax.set_xlabel('Año de la encuesta'); ax.set_ylabel('Tasa de inasistencia (%)')
ax.set_xticks(evo.index); ax.legend(title='Zona')
plt.savefig(DIR_FIG / '04_evolucion_tasa.png'); plt.show()
```


	zona	Rural	Urbana
anio_encuesta			
2022		12.840	5.240
2023		11.360	4.850
2024		10.800	5.100



Etapa 5 — Análisis descriptivo y exploratorio


Mínimo **ocho visualizaciones distintas**, cada una con título descriptivo, ejes rotulados con unidades, leyenda cuando corresponda, escala que no distorsione y una **interpretación escrita de una a tres oraciones inmediatamente debajo**. Todas las cifras están ponderadas por el factor de expansión.

```
In [24]: # === G1 · Serie temporal – tasa de inasistencia por zona (2022-2024) =====
fig, ax = plt.subplots(figsize=(10, 5))
for col in evo.columns:
    ax.plot(evo.index, evo[col], marker='o', lw=2.2, label=col)
ax.set_title('G1 · Evolución de la tasa de inasistencia escolar (12-17 años)')
ax.set_xlabel('Año de la encuesta'); ax.set_ylabel('Tasa de inasistencia (%)')
ax.set_xticks(evo.index); ax.legend(title='Zona')
plt.savefig(DIR_FIG / 'G1_serie_tasa_zona.png'); plt.show()
```



Interpretación G1. La brecha urbano/rural es estructural: en los tres años la tasa rural más que duplica a la urbana. En 2022 la diferencia es de 7,6 puntos porcentuales (12,8 % rural frente a 5,2 % urbana); en 2024 se reduce a 5,7 pp (10,8 % frente a 5,1 %). La convergencia se debe casi por entero a la caída rural (−2,0 pp); la urbana se mantiene en torno al 5 %. Aun así, en 2024 un adolescente rural sigue teniendo más del doble de inasistencia que uno urbano. El fenómeno no es un episodio de un solo año.


```
In [25]: # === G2 · Histograma – distribución de edad en el universo de análisis ===
fig, ax = plt.subplots(figsize=(9, 4.8))
sns.histplot(data=final, x='edad', weights='factor_expansion', bins=6, discr
ax.set_title('G2 · Distribución ponderada de la edad, personas de 12 a 17 añ
ax.set_xlabel('Edad (años)'); ax.set_ylabel('Población representada (persona
plt.savefig(DIR_FIG / 'G2_histograma_edad.png'); plt.show()
```



Interpretación G2. Con seis edades consecutivas, la distribución ponderada es la esperada de un universo bien cubierto: cada edad simple representa entre 16,2 % y 17,3 % (máximo en 13 años, mínimo en 15). No hay un año que desaparezca del perfil. El detalle a vigilar es 2024, con menos 17 años en la muestra (894 casos frente a 1.125 en 2022); para las tasas nacionales y por zona el efecto es menor, pero conviene no sobreinterpretar cortes muy finos de ese año x edad.

```
In [26]: # === G3 · Diagrama de caja/violín – edad según condición de asistencia ===
fig, ax = plt.subplots(figsize=(8, 5))
sns.violinplot(data=final, x='no_asiste', y='edad', ax=ax, inner='quartile',
ax.set_xticklabels(['Asiste', 'No asiste'])
ax.set_title('G3 · Distribución de edad según condición de asistencia actual
ax.set_xlabel(''); ax.set_ylabel('Edad (años)')
plt.savefig(DIR_FIG / 'G3_edad_asistencia.png'); plt.show()
```


```
/var/folders/lp/flhffk1951v91kr4yx185z3m0000gn/T/ipykernel_38871/3570236787.
py:4: UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator. Otherwise, ticks m
ay be mislabeled.
ax.set_xticklabels(['Asiste', 'No asiste'])
```



Interpretación G3. Sí: la inasistencia se concentra en 16–17 años. El violín de quienes no asisten se carga hacia el techo del rango (mediana 16 años; media ponderada 15,8), mientras que quienes asisten se reparte de forma casi simétrica entre 12 y 17 (media 14,4). La tasa ponderada crece de 1,3 % (12 años) a 4,9 % (14), 7,5 % (15), 11,9 % (16) y 19,1 % (17). El salto coincide con el paso al 3.er ciclo y, sobre todo, a la educación media: el problema no está “repartido” en la adolescencia, se agrava al final de la escolaridad obligatoria de hecho.

```
In [27]: # === G4 · Barras comparativas – tasa de inasistencia por departamento ===
tab_dpto = tabla_tasas_por_grupo(final, 'departamento')
fig, ax = plt.subplots(figsize=(10, 7))
colores = ['#c44e52' if n < 150 else '#4c72b0' for n in tab_dpto['n_muestral']]
ax.barh(tab_dpto.index[::-1], tab_dpto['tasa_%'][:,::-1], color=colores[:,::-1])
ax.axvline(tasa_ponderada(final, 'no_asiste'), color='black', ls='--', lw=1.5,
           label=f'Media nacional ({tasa_ponderada(final, "no_asiste"):.1f}%)')
ax.set_title('G4 · Tasa de inasistencia escolar (12–17 años) por departamento')
ax.set_xlabel('Tasa de inasistencia (% , ponderada)'); ax.set_ylabel('Departamento')
ax.legend()
ax.text(.98, .02, 'En rojo: departamentos con n muestral < 150 (estimación m',
       transform=ax.transAxes, ha='right', fontsize=8, style='italic')
plt.tight_layout(); plt.savefig(DIR_FIG / 'G4_barras_departamento.png'); plt
display(tab_dpto.round(2))
```

G4 · Tasa de inasistencia escolar (12-17 años) por departamento, 2022-2024




	n_muestral	poblacion_ponderada	tasa_%
departamento			
Itapúa	1,637.000	152,608.450	12.830
San Pedro	1,310.000	126,576.030	12.600
Canindeyú	1,053.000	62,576.550	11.610
Guairá	752.000	61,798.790	11.610
Caaguazú	1,250.000	166,246.500	10.750
Amambay	848.000	46,910.960	10.460
Alto Paraná	2,210.000	225,970.980	9.320
Caazapá	1,089.000	58,313.210	8.600
Concepción	810.000	74,905.620	8.020
Presidente Hayes	683.000	28,090.540	7.790
Cordillera	973.000	84,877.020	6.470
Ñeembucú	465.000	19,497.850	5.350
Central	2,829.000	531,119.150	4.680
Misiones	800.000	32,614.130	4.620
Paraguarí	763.000	63,843.630	3.710
Capital	1,086.000	110,571.130	1.790

Interpretación G4. Las tasas más altas están en Itapúa (12,8 %) y San Pedro (12,6 %), seguidas por Canindeyú y Guairá (~11,6 %). Las más bajas están en Capital (1,8 %), Paraguarí (3,7 %), Misiones y Central (~4,6 %). La media nacional es 7,8 %. Ningún departamento cae por debajo de $n = 150$ (el umbral que el gráfico marca en rojo): el más chico es Ñeembucú ($n = 465$; 22 no asistentes). Ese extremo bajo, y también Guairá ($n = 752$) o Presidente Hayes ($n = 683$), deben leerse con más cautela que Itapúa ($n = 1.637$) o Central ($n = 2.829$). Capital tiene $n = 1.086$, así que su tasa muy baja no es un artefacto de muestra minúscula.

```
In [28]: # === G5 · Mapa de calor – motivo de inasistencia según zona =====
cont_motivo_pct = (100 * cont_motivo.div(cont_motivo.sum(axis=0), axis=1))
fig, ax = plt.subplots(figsize=(8, 7))
sns.heatmap(cont_motivo_pct, annot=True, fmt='.1f', cmap='Reds', ax=ax,
             cbar_kws={'label': '% dentro de la zona'})
ax.set_title('G5 · Motivo de inasistencia declarado, según zona (% dentro de
ax.set_xlabel('Zona'); ax.set_ylabel('Motivo declarado')
plt.tight_layout(); plt.savefig(DIR_FIG / 'G5_heatmap_motivo_zona.png'); plt
```


G5 · Motivo de inasistencia declarado, según zona (% dentro de cada zona)



Interpretación G5. El motivo económico ("sin recursos en el hogar") es el primero en **ambas** zonas y con la misma magnitud (~27,5 %). Lo que sí cambia con la zona es la oferta educativa: "no existe institución cercana" explica el 11,2 % de la inasistencia rural y apenas el 0,8 % de la urbana. En zona urbana pesan más "no quiere estudiar" (25,1 % vs. 20,4 %) y "necesidad de trabajar" (11,8 % vs. 8,9 %). La política no puede ser la misma: en el área rural hay un problema de **acceso físico** que en la urbana casi no aparece; en la urbana pesan más la decisión personal y el trabajo.


```
In [29]: # === G6 · Barras – top motivos de inasistencia a nivel nacional ===
motivo_nac = (no_asisten.groupby('motivo_inasistencia')['factor_expansion'].
              .sort_values(ascending=False))
motivo_nac_pct = (100 * motivo_nac / motivo_nac.sum())
fig, ax = plt.subplots(figsize=(10, 6))
ax.barh(motivo_nac_pct.index[::-1], motivo_nac_pct.values[::-1], color='#dd8888')
ax.set_title('G6 · Motivos declarados de inasistencia escolar, 12-17 años (rural y urbana)')
ax.set_xlabel('Participación en el total de inasistentes (% ponderada)');
plt.tight_layout(); plt.savefig(DIR_FIG / 'G6_motivos_nacional.png'); plt.show()
```

G6 · Motivos declarados de inasistencia escolar, 12-17 años (nacional, 2022-2024)




Interpretación G6. A nivel nacional, tres motivos concentran el 70 % de la inasistencia ponderada: **sin recursos en el hogar (27,6 %)**, **no quiere estudiar (22,2 %)** y **motivos familiares (20,4 %)**. Agrupados: el bloque **económico** (recursos + necesidad de trabajar + costo de materiales) ronda el 39 %; el **familiar** el 20 %; el de **interés/decisión personal** (~22–24 %); y el de **oferta educativa** (institución inexistente, incompleta, mala o cerrada) cerca del 8 %, muy concentrado en zona rural. La implicancia de política es doble: las transferencias o el costo de asistir importan, pero no agotan el fenómeno —hay un componente de motivación y otro de oferta territorial que no se resuelven con el mismo instrumento.

```
In [30]: # === G7 · Barras agrupadas – sector educativo por zona (entre quienes asiste)
cont_pct = (100 * cont.div(cont.sum(axis=1), axis=0))
ax = cont_pct.plot(kind='bar', figsize=(9, 5.5), width=.7)
ax.set_title('G7 · Composición por sector educativo, según zona (entre quienes asiste)')
ax.set_xlabel('Zona'); ax.set_ylabel('% dentro de la zona (ponderado)')
ax.legend(title='Sector'); plt.xticks(rotation=0)
plt.tight_layout(); plt.savefig(DIR_FIG / 'G7_sector_por_zona.png'); plt.show()
```



Interpretación G7. Entre quienes asisten, el sector oficial cubre el 93 % del área rural y el 75 % del área urbana. El privado más el privado subvencionado apenas llegan al 7 % en zona rural, frente al 25 % en zona urbana (15 % privado y 10 % subvencionado). La oferta no oficial es, en la práctica, un fenómeno urbano. Eso refuerza G5: si en el campo no hay institución cercana, casi no hay un colegio privado que la sustituya. Cualquier política de retención rural depende de la escuela oficial.

```
In [31]: # === G8 · Dispersión – tasa de inasistencia vs. tamaño de la submuestra por
fig, ax = plt.subplots(figsize=(9, 6))
sns.scatterplot(data=tab_dpto.reset_index(), x='n_muestral', y='tasa_%', s=9)
for _, fila in tab_dpto.reset_index().iterrows():
    ax.annotate(fila['departamento'], (fila['n_muestral'], fila['tasa_%']),
                xytext=(4, 4), textcoords='offset points')
ax.axhline(tasa_ponderada(fila, 'no_asiste'), color='black', ls='--', lw=1)
ax.set_title('G8 · Tasa de inasistencia por departamento frente al tamaño de
ax.set_xlabel('Casos muestrales en el departamento (n)'); ax.set_ylabel('Tas
plt.tight_layout(); plt.savefig(DIR_FIG / 'G8_dispersion_n_tasa.png'); plt.s
```



Interpretación G8. Las tasas más altas **no** son las de los departamentos más chicos: Itapúa y San Pedro combinan tasa elevada (>12 %) con n muestral holgado (1.637 y 1.310). Central, con el n más grande (2.829), tiene una de las tasas más bajas (4,7 %). El extremo que sí exige cautela es Ñeembucú (n = 465, tasa 5,3 %) y, en menor medida, Misiones, Paraguari y Guairá (n entre 750 y 800). Conclusión metodológica para la Fase 2: no descartar los máximos de Itapúa/San Pedro como “ruido de muestra chica”; sí inflar la incertidumbre de los departamentos con menos de ~800 casos.

5.2. Patrones y anomalías identificados

N.º	Patrón o anomalía	Evidencia	Lectura
P1	La tasa rural más que duplica a la urbana en 2022, 2023 y 2024 (11,7 % vs. 5,1 % en el pooled). La brecha se estrecha de 7,6 a 5,7 pp, por caída rural, no por suba urbana.	G1; serie temporal	Brecha estructural. La mejora 2022–2024 no cierra el problema.
P2	La inasistencia crece de forma monótona con la edad: 1,3 % a los 12 años y 19,1 % a los 17. Quienes no asisten tienen ~1,4 años más en promedio.	G3; tasas por edad	El fenómeno es de <i>salida progresiva</i> , concentrado en el tramo de educación media.

N.º	Patrón o anomalía	Evidencia	Lectura
P3	Tres motivos (recursos del hogar, no quiere estudiar, motivos familiares) concentran ~70 % de los casos. "No existe institución cercana" es casi exclusivamente rural (11,2 % vs. 0,8 %).	G5, G6	La política debe diferenciar zona: acceso físico en el campo; motivación y trabajo en la ciudad. El costo económico es transversal.
P4	Itapúa y San Pedro lideran la tasa (~12,6–12,8 %) con n muestral grande; Capital tiene 1,8 % con n = 1.086.	G4, G8	La jerarquía territorial no es un artefacto de muestra chica en los extremos más relevantes.
A1	Ñeembucú (n = 465) y, en menor grado, Guairá y Presidente Hayes tienen n más ajustado. Boquerón y Alto Paraguay no entran en la muestra.	G8; Etapa 2.6	No sobreinterpretar esos departamentos. Nada de este proyecto se extiende al Chaco central/norte.

5.3. Hipótesis preliminares para la Fase 2

Este es el **punto entre fases** y su ausencia se penaliza. Cada hipótesis deriva de algo observado arriba. La prueba definitiva depende de la verificación de supuestos en la Fase 2, y deberá decidirse si se trabaja sobre el n muestral real, sobre la población ponderada, o con métodos específicos de encuestas complejas (a discutir con el docente).

N.º	Hipótesis (lenguaje natural)	Evidencia que la motiva	Prueba prevista	Familia	Tamaño de efecto
H1	La tasa de inasistencia es mayor en zona rural que en zona urbana.	G1, tabla 4.3	Prueba z de proporciones (o chi-cuadrado 2x2) sobre el n muestral real	Dos proporciones	h de Cohen o diferencia de proporciones con IC
H2	Existe asociación entre la zona y el motivo declarado de inasistencia (agrupado en categorías: económico, familiar, de oferta, personal).	G5, G6	Chi-cuadrado de independencia (Fisher si hay categorías con frecuencia baja)	Catagórica x catagórica	V de Cramér
H3	La tasa de inasistencia difiere entre departamentos.	G4	Chi-cuadrado de independencia (departamento x asiste/no asiste) o ANOVA/Kruskal-Wallis sobre proporciones por conglomerado	Tres o más grupos	eta cuadrado o V de Cramér

N.º	Hipótesis (lenguaje natural)	Evidencia que la motiva	Prueba prevista	Familia	Tamaño de efecto
H4	La tasa de inasistencia aumenta con la edad dentro del rango 12-17 años.	G3	Prueba sobre rho de Spearman entre edad y condición de inasistencia, o regresión logística simple	Correlación / asociación ordinal	rho o razón de momios
H5	La diferencia urbano/rural en inasistencia persiste al controlar por departamento.	P3 sugiere que zona y departamento pueden confundirse	Regresión logística múltiple: inasistencia ~ zona + departamento + edad + sexo	Efecto controlando otras	razón de momios (OR) por variable

Cobertura de familias: H1 (dos proporciones) · H2 (asociación categórica) · H3 (tres o más grupos) · H4 (correlación/asociación ordinal) · H5 (regresión múltiple) → **cinco familias distintas**, por encima del mínimo de tres exigido.

Previsiones para la Fase 2

- $\alpha = 0,05$ declarado **antes** de ejecutar cualquier prueba.
- Corrección de **Benjamini-Hochberg** sobre la familia H1–H4, por tratarse de contrastes múltiples sobre el mismo fenómeno.
- **Decisión metodológica a resolver con el docente:** si los contrastes formales se ejecutan sobre el **n muestral real** (más conservador, pero ignora el diseño de ponderación) o replicando el peso muestral con técnicas de remuestreo. Se documentará la elección y su justificación al inicio de la Fase 2.
- **Confusor principal a discutir:** zona y departamento pueden estar correlacionados (algunos departamentos son mayoritariamente rurales); H5 existe justamente para separar ambos efectos.

6. Conclusión de la Fase 1

6.1. Principales resultados obtenidos

El universo analizado son **18.558 adolescentes de 12 a 17 años** en las rondas 2022–2024 de la EPHC, que representan a **1,85 millones** de personas una vez aplicado el factor de expansión. La tasa nacional ponderada de inasistencia es **7,8 %** y baja levemente en el período (8,5 % en 2022 → 7,4 % en 2024).

Esa media esconde una brecha territorial persistente. En zona **rural** la tasa pooled es **11,7 %**; en zona **urbana**, **5,1 %**. La diferencia se mantiene los tres años y se reduce ~2

pp porque cae la rural, no porque suba la urbana (G1). Entre departamentos el rango va de **1,8 % en Capital** a **12,8 % en Itapúa**; San Pedro, Canindeyú, Guairá y Caaguazú también quedan claramente por encima de la media nacional (G4).

Por edad el patrón es nítido: a los 12 años casi no hay inasistencia (1,3 %); a los 17 llega al **19,1 %** (G3). Por sexo, los varones (8,8 %) superan a las mujeres (6,8 %). Los motivos declarados no son un residual: **sin recursos en el hogar (27,6 %)**, **no quiere estudiar (22,2 %)** y **motivos familiares (20,4 %)** concentran siete de cada diez casos; la falta de institución cercana es el quinto motivo nacional (7,3 %) pero el diferencial más claro entre zonas (G5, G6). Entre quienes asisten, la escuela oficial cubre el 93 % del campo y el 75 % de la ciudad (G7).

6.2. Respuesta parcial a la pregunta de investigación

Con análisis **descriptivo y ponderado** se puede afirmar que zona y departamento **sí se asocian** con la inasistencia en este tramo de edad, en la dirección esperada y con una magnitud grande: más del doble rural vs. urbana, y un abanico de ~11 pp entre Capital e Itapúa. También se puede afirmar que los hogares explican la inasistencia sobre todo con razones económicas, de motivación y familiares, y que la **oferta educativa** aparece como motivo relevante casi sólo en zona rural.

Lo que **todavía no** se puede afirmar: (i) si esas diferencias son estadísticamente sostenibles una vez se usa el n muestral real o un diseño de encuesta compleja (Fase 2, H1–H3); (ii) si la brecha urbano/rural sobrevive al controlar departamento, edad y sexo (H5), porque varios departamentos de alta tasa son predominantemente rurales; (iii) si zona, departamento, edad y sexo anticipan el riesgo individual de inasistencia mejor que una línea base (Fase 3). Nada de lo anterior es causal: la EPHC no identifica el establecimiento ni sigue a las mismas personas en el tiempo.

6.3. Limitaciones detectadas en los datos

1. **Cobertura del Chaco.** Boquerón y Alto Paraguay no aparecen en ninguno de los tres años; el alcance geográfico del proyecto se detiene ahí (Etapa 2.6).
2. **Precisión desigual por departamento.** Ñeembucú (n = 465) y otros departamentos con n < 800 tienen estimaciones más ruidosas (G8). Itapúa y San Pedro, en cambio, combinan tasa alta con muestra grande.
3. **Sin variables de establecimiento.** No hay infraestructura, planta docente ni servicios del colegio; la Fase 3 queda limitada a predictores territoriales y demográficos.
4. **Corte transversal repetido, no panel.** 2022–2024 son tres fotografías comparables, no la trayectoria de los mismos adolescentes.
5. **Motivo autorreportado** por el hogar, no auditado. “No quiere estudiar” puede ocultar barreras económicas o de calidad.

6. **Errores estándar.** Esta fase usa el FEX para estimaciones puntuales, no corrige por conglomerados/estratos. Los contrastes de la Fase 2 deben declarar esa salvedad.
7. **Chi-cuadrado exploratorio sobre población expandida.** El V de Cramér zona × sector (0,23) describe asociación, pero el p-valor inflado no se usa como prueba formal.

6.4. Decisiones que condicionan las fases siguientes

- El universo queda fijado en **12–17 años** y la variable objetivo en **no_asiste** (binaria, derivada de ED08 = 19).
- Todo descriptivo de esta fase está **ponderado por factor_expansion**. En Fase 2 hay que decidir, con el docente, si los contrastes van sobre el n muestral (más conservador) o con replicación de pesos.
- Los factores de expansión extremos **se conservaron**: son diseño, no error de carga.
- No se imputó **motivo_inasistencia** ni **sector** cuando corresponden a no asistencia o a no respuesta; el 91,6 % de nulos en motivo es estructural (quienes asisten).
- Sin identificador de establecimiento, la Fase 3 no puede incorporar variables institucionales del MEC. Los predictores disponibles son zona, departamento, edad y sexo (y, con cuidado, sector sólo entre quienes asisten: no sirve para predecir inasistencia).

6.5. Hipótesis que se llevan a la Fase 2

En este orden de prioridad, porque cada una cierra un hueco de la pregunta:

1. **H1** — tasa rural > tasa urbana (prueba de dos proporciones). Es el resultado descriptivo más estable (G1).
2. **H4** — la inasistencia aumenta con la edad (Spearman o logística simple). El gradiente 12→17 es el más nítido del análisis (G3).
3. **H3** — la tasa difiere entre departamentos (chi-cuadrado / Kruskal-Wallis), con nota de precisión para n chico (G4, G8).
4. **H2** — zona y motivo (agrupado: económico, familiar, oferta, personal) no son independientes (G5, G6).
5. **H5** — la brecha urbano/rural persiste al controlar departamento, edad y sexo (logística múltiple). Es la que evita confundir “rural” con “departamento pobre”.

Para la Fase 3, la etiqueta de clasificación es **no_asiste**. Línea base natural: clasificador nulo (todos asisten) o una logística sólo con zona.

7. Declaración de uso de asistentes de IA

Requerido por la sección 11 del enunciado.

Tarea	¿Se usó IA?	Detalle
Definición de la pregunta y de los objetivos	Parcial	El grupo definió el recorte EPHC (12–17, zona/departamento/motivo). Se usó asistencia para redactar y ordenar objetivos.
Estructura del notebook y del informe	Sí	Organización por etapas, plantilla de tablas y esqueleto del informe.
Escritura y depuración de código	Sí	Carga con <code>decimal=''</code> , ponderación, gráficos G1–G8, bitácora y exportación. El grupo ejecutó y verificó las salidas.
Selección de pruebas y decisiones metodológicas	Parcial	Conservar el FEX, no imputar motivos y las cinco familias de H1–H5 se discutieron con asistencia y se retuvieron porque calzan con lo observado.
Interpretación de resultados y conclusiones	Sí	Las interpretaciones G1–G8, los patrones P1–P4 y la conclusión se redactaron a partir de las cifras del notebook ejecutado. El grupo es responsable de su contenido.
Redacción del informe	Sí	Informe de Fase 1 y documento de comprensión del problema.

El grupo declara haber **verificado y comprendido** todo el código y todo el texto incorporado, y estar en condiciones de responder sobre cualquier línea del trabajo durante la presentación final.

8. Matriz de contribución

Tarea	Matías Morínigo	César Vielman	Iván Paredes
Comprensión del problema y pregunta	●	●	●
Descarga y organización de microdatos			●
Limpieza, código y reproducibilidad	●	●	●
Análisis exploratorio e interpretaciones	●	●	●
Informe, PDF y entrega	●	●	●

```
In [32]: # =====
# Verificación automática de los entregables de la Fase 1
# =====
chequeos = [
    ('1 · Documento de comprensión del problema (PDF 2–3 pp.)', (RAIZ/'outpu
    ('2 · Informe de la Fase 1 (PDF ≤ 20 pp.)', (RAIZ/'outpu
    ('3 · Notebook ejecutado de principio a fin sin errores', True),
    ('3b · Exportación HTML del notebook', any(RAIZ.rgl
    ('4 · Diccionario de datos original', (DIR_TAB/'di
```

```

('4b · Diccionario de datos final', (DIR_TAB/'di
('5 · Dataset limpio', any(DIR_PROG
('6 · README de reproducción', (RAIZ/'READM
('6b · Archivo de dependencias', (RAIZ/'requi
(' · Bitácora de limpieza', (DIR_TAB/'bi
(' · Ocho visualizaciones generadas', len(list(DIF
(' · Serie temporal 2022-2024 incluida', (DIR_TAB/'se
]
for nombre, ok in chequeos:
    print(f'{"✅" if ok else "❌"} {nombre}')
pend = [n for n, ok in chequeos if not ok]
print(f'\n{len(chequeos)-len(pend)}/{len(chequeos)} listos.')
if pend:
    print('Pendientes (dependen del grupo, no del código):')
    for p in pend:
        print(' · ', p)

```

- ✅ 1 · Documento de comprensión del problema (PDF 2-3 pp.)
- ✅ 2 · Informe de la Fase 1 (PDF ≤ 20 pp.)
- ✅ 3 · Notebook ejecutado de principio a fin sin errores
- ✅ 3b · Exportación HTML del notebook
- ✅ 4 · Diccionario de datos original
- ✅ 4b · Diccionario de datos final
- ✅ 5 · Dataset limpio
- ✅ 6 · README de reproducción
- ✅ 6b · Archivo de dependencias
- ✅ · Bitácora de limpieza
- ✅ · Ocho visualizaciones generadas
- ✅ · Serie temporal 2022-2024 incluida

12/12 listos.