

Proyecto Integrador de Ciencia de Datos — Fase 1

Inasistencia escolar en la adolescencia paraguaya: magnitud, motivos declarados y brechas territoriales (2022–2025)

Asignatura	Data Science
Fase	1 de 3 — Ponderación 30 %
Integrantes	Matías Morínigo · César Vielman · Iván Paredes
Fecha de entrega	Martes 15 de septiembre
Fuente	Encuesta Permanente de Hogares Continua (EPHC) — Dirección General de Estadística, Encuestas y Censos (DGEEC), Paraguay
Archivos	REG02_EPHC_ANUAL_2022.csv · _2023.csv · _2024.csv · _2025.csv (registro de personas, Sección 4 — Educación)

Por qué se cambió la fuente de datos

La propuesta original de este proyecto preguntaba por los **factores institucionales** (servicios básicos, infraestructura) asociados al **abandono escolar** entre 2015 y 2024, usando registros administrativos del Ministerio de Educación y Ciencias (MEC). Al inventariar los archivos efectivamente disponibles en el portal del MEC se comprobó que:

1. Los datasets de matrícula del MEC cubren un único año lectivo (2023) en el corte descargado.
2. **Ningún dataset del MEC contiene una variable de abandono, deserción o repitencia.**
3. Las variables de servicios básicos existen (`servicios_basicos` de FONACIDE), pero atadas a establecimientos priorizados para inversión, no al universo completo de instituciones ni a una serie temporal comparable.

La **EPHC de la DGEEC**, en cambio, sí trae —todos los años, con metodología estable— la pregunta **ED08** (si la persona asiste actualmente) y, crucialmente, **ED10**: *"¿Por qué no asiste o dejó de asistir?"*, con el motivo declarado por el propio hogar. Es la variable de abandono que la propuesta original necesitaba y que el MEC no publica en datos

abiertos. El costo de este cambio es real y se declara sin rodeos: la unidad de análisis deja de ser el *establecimiento* y pasa a ser la *persona dentro de un hogar*, con un diseño muestral complejo que exige usar el factor de expansión (FEX) en todo cálculo descriptivo.

Si en el futuro se consigue el dataset `servicios_basicos` del MEC a nivel de establecimiento y con cobertura nacional, se podría intentar una estimación de disponibilidad de servicios **por departamento** y cruzarla con las tasas de inasistencia calculadas aquí. Esa vía queda anotada como trabajo futuro.

Cómo usar este notebook

1. Los CSV (`REG02_EPHC_ANUAL_2022.csv` ... `_2025.csv`) van en `data/raw/` , sin modificar.
2. `Kernel → Restart & Run All` . El notebook corre de principio a fin y regenera `data/processed/dataset_fase1.parquet` .
3. Debajo de cada gráfico (G1–G8) está la lectura que hicimos de ese resultado.
4. Ninguna transformación se hace a mano. Todo queda documentado en la bitácora de limpieza (Etapa 3.6).

0. Configuración y reproducibilidad

```
In [1]: # =====
# Imports y configuración global
# =====

import re
import sys
import warnings
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats

warnings.filterwarnings('ignore', category=FutureWarning)

SEMILLA = 42
np.random.seed(SEMILLA)

RAIZ = Path.cwd().parent if Path.cwd().name == 'notebooks' else Path.cwd()
DIR_RAW = RAIZ / 'data' / 'raw'
DIR_PROC = RAIZ / 'data' / 'processed'
DIR_FIG = RAIZ / 'output' / 'figuras'
```

```

DIR_TAB = RAIZ / 'output' / 'tablas'
for _d in (DIR_RAW, DIR_PROC, DIR_FIG, DIR_TAB):
    _d.mkdir(parents=True, exist_ok=True)

sns.set_theme(style='whitegrid', palette='deep')
plt.rcParams.update({'figure.figsize': (10, 5), 'figure.dpi': 110, 'savefig.'
                        'savefig.bbox': 'tight', 'axes.titlesize': 13, 'axes.ti
                        'axes.labelsize': 11, 'font.size': 10})
pd.set_option('display.max_columns', 60)
pd.set_option('display.width', 170)
pd.set_option('display.float_format', lambda v: f'{v:,.3f}')

print('Python:', sys.version.split()[0], '| pandas:', pd.__version__, '| num
print('Raíz :', RAIZ)

```

Python: 3.12.4 | pandas: 3.0.5 | numpy: 2.5.3

Raíz : /Users/ivanparedesozuna/Developer/proyecto-ds-inasistencia-py

```

In [2]: # =====
# CONFIG – único lugar a tocar si cambian los archivos o los códigos de vari
# =====

ARCHIVOS_EPHC = {
    2022: 'REG02_EPHC_ANUAL_2022.csv',
    2023: 'REG02_EPHC_ANUAL_2023.csv',
    2024: 'REG02_EPHC_ANUAL_2024.csv',
    2025: 'REG02_EPHC_ANUAL_2025.csv',
}

# Columnas del registro de personas (REG02) que se necesitan para este proy
# El archivo real trae >200 columnas; sólo se cargan las que se van a usar.
COLUMNAS_NECESARIAS = [
    'UPM', 'NVIVI', 'NHOGA', 'AÑO', 'DPT0', 'AREA', 'L02',
    'P02',      # edad
    'P06',      # sexo (1 = Hombre, 6 = Mujer)
    'P04',      # es miembro del hogar
    'ED03',     # ¿asistió alguna vez a enseñanza formal?
    'ED08',     # ¿asiste actualmente? (19 = No asiste)
    'ED09',     # sector de la institución (1 Oficial, 2 Privado, 3 Privado
    'ED10',     # motivo de no asistencia / abandono
    'FEX.2022', # factor de expansión 2022–2024
    'FACTOR',   # factor de expansión 2025 (mismo rol; se unifica al cargar)
]

# Rango etario de interés: 3er ciclo de la EEB + educación media en Paraguay
# (edad teórica 12 a 17 años). Se declara aquí y se valida empíricamente en
EDAD_MIN, EDAD_MAX = 12, 17

# --- Diccionarios de categorías, tomados del diccionario oficial de variabl
MAPA_AREA = {1: 'Urbana', 6: 'Rural'}
MAPA_SEX0 = {1: 'Hombre', 6: 'Mujer'}
MAPA_ED09_SECTOR = {1: 'Oficial', 2: 'Privado', 3: 'Privado subvencionado',

MAPA_DPT0 = {
    0: 'Capital', 1: 'Concepción', 2: 'San Pedro', 3: 'Cordillera', 4: 'Guai
    5: 'Caaguazú', 6: 'Caazapá', 7: 'Itapúa', 8: 'Misiones', 9: 'Paraguarí',

```

```

10: 'Alto Paraná', 11: 'Central', 12: 'Ñeembucú', 13: 'Amambay', 14: 'Ca
15: 'Presidente Hayes', 16: 'Boquerón', 17: 'Alto Paraguay',
}

MAPA_ED10_MOTIVO = {
    1: 'Sin recursos en el hogar', 2: 'Necesidad de trabajar',
    3: 'Muy costosos materiales y matrículas', 4: 'No tiene edad adecuada',
    5: 'Considera que terminó los estudios', 6: 'No existe institución cerca',
    7: 'Institución cercana muy mala', 8: 'El centro educativo cerró',
    9: 'El docente no asiste con regularidad', 10: 'Institución no ofrece es
    11: 'Requiere educación especial', 12: 'Por enfermedad',
    13: 'Debe hacer labores en el hogar', 14: 'Motivos familiares',
    15: 'No quiere estudiar', 16: 'Asiste a formación profesional/vocacional',
    17: 'Servicio militar', 18: 'Otra razón', 99: 'NR',
}

# ED08: 19 = 'No asiste'; el resto de los códigos (1-18) corresponden a 'Sí',
COD_NO_ASISTE = 19

print('Configuración cargada. Archivos esperados:')
for anio, nombre in ARCHIVOS_EPHC.items():
    ruta = DIR_RAW / nombre
    print(f' {anio}: {nombre:32} {"✅ encontrado" if ruta.exists() else "❌ no encontrado"}')

```

```

Configuración cargada. Archivos esperados:
2022: REG02_EPHC_ANUAL_2022.csv      ✅ encontrado
2023: REG02_EPHC_ANUAL_2023.csv      ✅ encontrado
2024: REG02_EPHC_ANUAL_2024.csv      ✅ encontrado
2025: REG02_EPHC_ANUAL_2025.csv      ✅ encontrado

```

Etapa 1 — Comprensión del problema

1.1. Contexto del problema

La **Dirección General de Estadística, Encuestas y Censos (DGEEC)** de Paraguay releva anualmente la **Encuesta Permanente de Hogares Continua (EPHC)**, una encuesta muestral probabilística a hogares que releva, entre otras dimensiones, la situación educativa de cada miembro del hogar: si asiste actualmente a una institución de enseñanza formal, a qué nivel, en qué sector, y —si no asiste o dejó de asistir— **por qué**. La encuesta usa un diseño muestral complejo con unidades primarias de muestreo (UPM) y un factor de expansión (**FEX**) que permite generalizar los resultados de la muestra a la población total del país.

La **decisión real en juego** es la misma que motivó la propuesta original del proyecto: cómo priorizar la inversión y las políticas de retención escolar. La diferencia es la fuente: en vez de partir del registro administrativo de establecimientos del MEC, este proyecto parte de la **voz del hogar**, que declara directamente por qué un adolescente no está en

la escuela. Esa información no la tiene el MEC —un establecimiento no puede reportar por qué un chico que nunca llegó a inscribirse dejó de estudiar— y es exactamente la que permite distinguir entre causas económicas, familiares, de oferta educativa o de interés personal.

Los usuarios potenciales del análisis son el MEC (para políticas de retención), el Ministerio de Desarrollo Social (para programas de transferencias condicionadas), las gobernaciones y organizaciones que monitorean la equidad educativa territorial.

1.2. Pregunta de investigación

¿En qué medida la zona de residencia (urbana/rural) y el departamento se asocian con la tasa de inasistencia escolar de los adolescentes de 12 a 17 años en Paraguay, y qué motivos declaran los hogares para explicar esa inasistencia, entre 2022 y 2025?

La pregunta cumple los tres criterios exigidos: se responde con **evidencia** (la EPHC, encuesta oficial de la DGEEC) y no con opinión; está **acotada** en tiempo (2022–2025, los cuatro años con archivo disponible), en edad (12 a 17 años, edad teórica de 3.er ciclo y educación media) y en alcance (zona, departamento y motivo declarado); y **admite respuesta negativa**: es posible que, controlando por departamento, la diferencia urbano/rural no resulte relevante, o que el motivo principal de inasistencia no varíe entre zonas.

1.3. Objetivo general

Analizar la asociación entre la zona de residencia, el departamento y la tasa de inasistencia escolar de los adolescentes de 12 a 17 años en Paraguay entre 2022 y 2025, caracterizando los motivos de inasistencia declarados por los hogares.

1.4. Objetivos específicos

N.º	Objetivo específico	Fase	Sección
OE1	Construir un panel 2022–2025 de personas de 12 a 17 años a partir de los cuatro registros anuales de la EPHC, con las variables de asistencia, motivo, zona, departamento y factor de expansión correctamente aplicado.	Fase 1	Etapas 2 y 3
OE2	Describir la evolución de la tasa de inasistencia escolar y de sus motivos declarados, por zona, departamento y sexo, entre 2022 y 2025.	Fase 1	Etapas 4 y 5
OE3	Determinar si la tasa de inasistencia difiere de forma estadísticamente significativa entre zonas	Fase 2 (inferencial)	Contrastes de hipótesis

N.º	Objetivo específico	Fase	Sección
	urbana y rural, y entre departamentos, y si el motivo declarado se asocia con la zona.		
OE4	Construir un modelo de clasificación que estime la probabilidad de inasistencia escolar de un adolescente a partir de su zona, departamento, edad y sexo, comparándolo contra una línea base.	Fase 3 (predictiva)	Modelado y evaluación
OE5	Comunicar los hallazgos y sus limitaciones —en particular las propias de trabajar con una encuesta muestral— en términos utilizables por responsables de política educativa.	Cierre	Informe y presentación

OE1 y OE2 se ejecutan íntegramente en esta fase. Las hipótesis preliminares de la sección 5.3 son el insumo directo de OE3 (Fase 2), y la selección de variables de la Etapa 3 define el espacio de atributos de OE4 (Fase 3).

1.5. Justificación de la relevancia

Paraguay ha ampliado su cobertura educativa en las últimas décadas, pero el 3.er ciclo de la escolar básica y la educación media siguen siendo el tramo donde más adolescentes salen del sistema. Las estadísticas agregadas de matrícula no explican **por qué** ocurre esa salida; la EPHC sí lo pregunta directamente. Un análisis que distinga si la inasistencia se debe mayoritariamente a razones económicas, familiares, de oferta educativa insuficiente o de decisión personal tiene una implicancia de política completamente distinta en cada caso: transferencias monetarias, programas de cuidado familiar, ampliación de la oferta escolar, o estrategias de motivación y orientación vocacional, respectivamente.

Además, al tratarse de una encuesta con cuatro años consecutivos, el proyecto puede documentar si la brecha urbano/rural se mantiene, se amplía o se reduce en el período reciente —algo que un corte único no permite.

1.6. Alcance y limitaciones previstas

Dentro del alcance

- Personas de **12 a 17 años** registradas en el hogar (P04 = miembro del hogar).
- Período **2022–2025** (los cuatro años con archivo disponible).
- Variables de **asistencia actual** (ED08), **motivo de inasistencia** (ED10), **sector** (ED09), **zona** (AREA), **departamento** (DPT0), **sexo** (P06) y **edad** (P02).
- Todo estadístico descriptivo se calcula **ponderado por el factor de expansión** (FEX.2022), como exige el diseño muestral de la encuesta.

Explícitamente fuera

- **Características del establecimiento** (infraestructura, servicios básicos, planta docente): la EPHC no identifica el establecimiento al que asiste o asistía la persona; esa información seguiría el registro administrativo del MEC. No se fuerza un cruce que la propia estructura de los datos no permite.
- **Seguimiento de cohorte.** La EPHC es una encuesta de **corte transversal repetido**, no un panel: no se entrevista a los mismos hogares cada año. "2022–2025" describe cuatro fotografías comparables, no la trayectoria de las mismas personas en el tiempo.
- **Inferencia causal.** Las asociaciones que se documenten son observacionales; nunca se afirma que la zona o el departamento *causen* la inasistencia, sólo que se *asocian* con ella.
- Niveles educativos fuera del rango 12–17 años (inicial, primaria temprana, superior).

Limitaciones de diseño que se declaran desde ahora

1. **Diseño muestral complejo.** La EPHC tiene estratificación y conglomerados (UPM); los cálculos de este proyecto usan el factor de expansión para las estimaciones puntuales, pero **no** corrigen los errores estándar por el efecto de diseño (eso requeriría el paquete de replicación de la DGEEC, fuera del alcance de la materia). Los intervalos de confianza de la Fase 2 deben leerse con esa salvedad.
2. **Tamaño de submuestra por departamento.** Algunos departamentos pequeños (Alto Paraguay, Boquerón, Ñeembucú) tienen pocas observaciones muestrales; sus estimaciones tendrán mayor error y se señalará explícitamente.
3. **El motivo de inasistencia es autorreportado** por el hogar, no verificado independientemente.
4. **Cobertura territorial incompleta en el Chaco.** Se verifica empíricamente en la Etapa 2.6 si Boquerón y Alto Paraguay están representados en la muestra de los tres años; si no lo están, los resultados de este proyecto no podrán extenderse a esa región y así se declarará en la conclusión.

Etapa 2 — Comprensión y selección de los datos

```
In [3]: # =====
# 2.1 – Inventario de los archivos disponibles
# =====
filas = []
for anio, nombre in ARCHIVOS_EPHC.items():
    ruta = DIR_RAW / nombre
    if not ruta.exists():
        filas.append({'archivo': nombre, 'anio': anio, 'estado': 'NO ENCONTRADO'})
        continue
    with open(ruta, encoding='utf-8-sig') as f:
```

```

n_cols = len(f.readline().split(';'))
n_filas = sum(1 for _ in open(ruta, encoding='utf-8-sig')) - 1
filas.append({'archivo': nombre, 'anio': anio, 'tamano_mb': round(ruta.s
                'filas': n_filas, 'columnas_totales': n_cols, 'estado': 'O

inventario = pd.DataFrame(filas)
display(inventario)
inventario.to_csv(DIR_TAB / 'inventario_archivos.csv', index=False)

```

	archivo	anio	tamano_mb	filas	columnas_totales	estado
0	REG02_EPHC_ANUAL_2022.csv	2022	29.000	61912	213	OK
1	REG02_EPHC_ANUAL_2023.csv	2023	26.900	58005	213	OK
2	REG02_EPHC_ANUAL_2024.csv	2024	27.100	57744	213	OK
3	REG02_EPHC_ANUAL_2025.csv	2025	25.800	55934	213	OK

2.1.1. Descripción del inventario

Los tres archivos son el **registro de personas (REG02)** de la EPHC anual, uno por año. Cada fila es una persona dentro de un hogar dentro de una vivienda. Comparten exactamente la misma estructura de columnas (213 en los tres casos), lo que permite concatenarlos directamente en un panel sin necesidad de mapear nombres de campo entre años —a diferencia de lo que suele ocurrir con fuentes administrativas.

Archivo	Año	Contenido	Unidad de análisis	Clave
REG02_EPHC_ANUAL_2022.csv	2022	Registro de personas, todas las secciones (incl. Educación)	persona	UPM + NVIVI + NHOGA + L0
REG02_EPHC_ANUAL_2023.csv	2023	ídem	persona	ídem
REG02_EPHC_ANUAL_2024.csv	2024	ídem	persona	ídem
REG02_EPHC_ANUAL_2025.csv	2025	ídem; el peso muestral se llama FACTOR (se unifica a FEX.2022 al cargar)	persona	ídem

```

In [4]: # =====
# 2.2 – Carga de los archivos
# =====

```



```
# ⚠ Detalle crítico de formato: el archivo usa ';' como separador de columnas
# y ',' como separador DECIMAL (formato numérico latinoamericano). Si se ignora
# el parámetro decimal=',', el factor de expansión FEX se lee como texto y
# cualquier .sum() posterior concatena strings en vez de sumar números,
# produciendo un resultado sin sentido y sin ningún error visible.
```

```
tablas_anuales = {}
for anio, nombre in ARCHIVOS_EPHC.items():
    ruta = DIR_RAW / nombre
    df_anio = pd.read_csv(ruta, sep=';', encoding='utf-8-sig', decimal=',',
                          usecols=lambda c: c in COLUMNAS_NECESARIAS, low_memory=False)
    df_anio.columns = df_anio.columns.str.replace('\r', '', regex=False)
    # 2022–2024: FEX.2022 · 2025: FACTOR (mismo concepto, otro nombre)
    if 'FACTOR' in df_anio.columns and 'FEX.2022' not in df_anio.columns:
        df_anio = df_anio.rename(columns={'FACTOR': 'FEX.2022'})
    df_anio['anio_encuesta'] = anio # se usa el año de archivo como ancla
    tablas_anuales[anio] = df_anio
    print(f'{nombre:32} -> {df_anio.shape[0]:>7,} filas × {df_anio.shape[1]} columnas'
          f'FEX dtype: {df_anio["FEX.2022"].dtype}')

crudo = pd.concat(tablas_anuales.values(), ignore_index=True)
anios = sorted(crudo.anio_encuesta.unique())
print(f'\nPanel unificado {anios[0]}–{anios[-1]}: {crudo.shape[0]:>7,} filas × {crudo.shape[1]} columnas'
      f'FEX dtype: {crudo["FEX.2022"].dtype}')
crudo.head()
```

```
REG02_EPHC_ANUAL_2022.csv    -> 61,912 filas × 16 columnas    FEX dtype: float64
REG02_EPHC_ANUAL_2023.csv    -> 58,005 filas × 16 columnas    FEX dtype: float64
REG02_EPHC_ANUAL_2024.csv    -> 57,744 filas × 16 columnas    FEX dtype: float64
REG02_EPHC_ANUAL_2025.csv    -> 55,934 filas × 16 columnas    FEX dtype: int64
```

Panel unificado 2022–2025: 233,595 filas × 16 columnas

```
Out[4]:
```

	UPM	NVIVI	NHOGA	AÑO	DPTO	AREA	L02	P02	P04	P06	ED03	ED08	ED10
0	14	10	1	2022	0	1	1	74	1	6	1		
1	14	10	1	2022	0	1	2	18	1	6	1	3	
2	14	20	1	2022	0	1	1	56	1	1	1		
3	14	20	1	2022	0	1	2	20	1	1	1	16	
4	14	22	1	2022	0	1	1	69	1	6	1		

```
In [5]: # =====
# 2.3 – Diccionario de datos (reconstruido por el grupo)
# =====
def diccionario_datos(df: pd.DataFrame, max_cat: int = 6) -> pd.DataFrame:
    filas = []
    for col in df.columns:
        s, nn = df[col], df[col].dropna()
        if pd.api.types.is_numeric_dtype(s) and nn.nunique() > max_cat:
            rango = f'[{nn.min():.2f} – {nn.max():.2f}]' if len(nn) else ''
```

```

else:
    cats = nn.astype(str).value_counts().index[:max_cat].tolist()
    extra = '' if nn.nunique() <= max_cat else f' ... ({nn.nunique()-
    rango = ', '.join(cats) + extra
    filas.append({'campo': col, 'tipo_detectado': str(s.dtype), 'tipo_co
                  'descripcion': '', 'unidad': '', 'n_unicos': s.nunique
                  'rango_o_categorias': rango, 'pct_faltantes': round(10
return pd.DataFrame(filas)

def completar_diccionario(dicc: pd.DataFrame, meta: dict) -> pd.DataFrame:
    """Rellena tipo_correcto, descripcion y unidad a partir del diccionario
    out = dicc.copy()
    for campo, (tipo, desc, unidad) in meta.items():
        mask = out['campo'] == campo
        out.loc[mask, 'tipo_correcto'] = tipo
        out.loc[mask, 'descripcion'] = desc
        out.loc[mask, 'unidad'] = unidad
    return out

META_ORIGINAL = {'UPM': ('entero', 'Unidad primaria de muestreo del diseño c

dicc_original = completar_diccionario(diccionario_datos(crudo), META_ORIGINAL)
dicc_original.to_csv(DIR_TAB / 'diccionario_datos_original.csv', index=False)
display(dicc_original)
print('Diccionario original completado con tipo, descripción y unidad (refer

```

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos	ra
0	UPM	int64	entero	Unidad primaria de muestreo del diseño de la EPHC	código	1827	[
1	NVIVI	int64	entero	Número de vivienda dentro de la UPM	código	173	
2	NHOGA	int64	entero	Número de hogar dentro de la vivienda	código	3	
3	AÑO	int64	entero	Año calendario de la ronda de la encuesta (cam...	año	4	
4	DPTO	int64	categórica ordinal (código)	Departamento de residencia (código DGEEC 0–15)	código	16	
5	AREA	int64	categórica (código)	Zona de residencia: 1 urbana, 6 rural	código	2	
6	L02	int64	entero	Número de línea / persona dentro del hogar	código	27	
7	P02	int64	entero	Edad en años cumplidos	años	107	
8	P04	int64	categórica (código)	Relación con el hogar (filtro: miembro del hogar)	código	1	
9	P06	int64	categórica (código)	Sexo: 1 hombre, 6 mujer	código	2	
10	ED03	str	categórica (código)	¿Sabe leer y escribir?	código	4	
11	ED08	str	categórica (código)	Nivel/modalidad al que asiste; 19 = no asiste	código	21	
12	ED09	str	categórica (código)	Sector de la institución (oficial, privado, su...	código	5	
13	ED10	str	categórica (código)	Motivo de no asistir o de haber dejado de asistir	código	20	

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos	ra
14	FEX.2022	float64	continuo	Factor de expansión muestral (FEX.2022 en 2022...	personas	36096	
15	anio_encuesta	int64	entero	Año de la ronda, reconstruido al concatenar lo...	año	4	

Diccionario original completado con tipo, descripción y unidad (referencia: diccionario_EPHC_ANUAL_2023.xls).

```
In [6]: # =====
# 2.4 – Unidad de análisis y clave: verificación EMPÍRICA de unicidad
# =====
CLAVE_PERSONA = ['UPM', 'NVIVI', 'NHOGA', 'L02', 'anio_encuesta']

dup = int(crudo.duplicated(subset=CLAVE_PERSONA).sum())
print(f'Clave candidata: {CLAVE_PERSONA}')
print(f'Filas totales           : {len(crudo):,}')
print(f'Combinaciones únicas de clave: {crudo[CLAVE_PERSONA].drop_duplicates}')
print(f'Filas duplicadas por esa clave: {dup:,}')
print(f'¿Es clave primaria dentro de cada año? {"✅ Sí" if dup == 0 else "❌ No"}')

# La unidad de análisis declarada en la Etapa 1.6 es la persona-año.
print('\nUnidad de análisis adoptada: PERSONA dentro de un HOGAR, observada
      '(corte transversal repetido, no panel de las mismas personas).')
```

```
Clave candidata: ['UPM', 'NVIVI', 'NHOGA', 'L02', 'anio_encuesta']
Filas totales           : 233,595
Combinaciones únicas de clave: 233,595
Filas duplicadas por esa clave: 0
¿Es clave primaria dentro de cada año? ✅ Sí
```

Unidad de análisis adoptada: PERSONA dentro de un HOGAR, observada en un AÑO de encuesta (corte transversal repetido, no panel de las mismas personas).

```
In [7]: # =====
# 2.5 – Perfilado inicial
# =====
print(f'Dimensiones: {crudo.shape[0]:,} filas × {crudo.shape[1]} columnas')
print(f'Memoria      : {crudo.memory_usage(deep=True).sum()/1024**2:,.1f} MB\r')

perfil = pd.DataFrame({
    'tipo_detectado': crudo.dtypes.astype(str),
    'n_unicos': crudo.nunique(dropna=True),
    'faltantes_%': (100*crudo.isna().mean()).round(2),
}).sort_values('faltantes_%', ascending=False)
display(perfil)

print('Distribución de edad (P02):')
display(crudo.P02.describe(percentiles=[.05, .25, .5, .75, .95]))
```

```
print('\nValores observados de ED08 (asistencia) – códigos crudos:')
print(crudo.ED08.value_counts(dropna=False).sort_index())
```

Dimensiones: 233,595 filas × 16 columnas

Memoria : 29.5 MB

	tipo_detectado	n_unicos	faltantes_%
UPM	int64	1827	0.000
NVIVI	int64	173	0.000
NHOGA	int64	3	0.000
AÑO	int64	4	0.000
DPTO	int64	16	0.000
AREA	int64	2	0.000
L02	int64	27	0.000
P02	int64	107	0.000
P04	int64	1	0.000
P06	int64	2	0.000
ED03	str	4	0.000
ED08	str	21	0.000
ED09	str	5	0.000
ED10	str	20	0.000
FEX.2022	float64	36096	0.000
anio_encuesta	int64	4	0.000

Distribución de edad (P02):

```
count    233,595.000
mean       32.854
std        21.912
min         0.000
5%         3.000
25%        14.000
50%        30.000
75%        49.000
95%        72.000
max       106.000
```

Name: P02, dtype: float64

Valores observados de ED08 (asistencia) – códigos crudos:

ED08

	71829
1	7403
10	38
11	39
12	470
13	685
14	2
15	91
16	10019
17	69
18	1381
19	93366
2	37546
3	8133
4	1742
5	21
6	249
7	430
8	1
9	2
99	79

Name: count, dtype: int64

In [8]:

```
# =====
# 2.6 – Evaluación de calidad
# =====

chequeos = []
chequeos.append(('Compleitud global', f'{100*(1-crudo.isna().mean().mean())}')
chequeos.append(('Cobertura temporal', f'{sorted(crudo.anio_encuesta.unique())}')
chequeos.append(('Filas duplicadas exactas', f'{crudo.duplicated().sum():,}')
chequeos.append(('Edad fuera de rango plausible (< 0 o > 110)',
                  f'{int(((crudo.P02 < 0) | (crudo.P02 > 110)).sum()):,}'))
chequeos.append(('Población total ponderada por año (FEX)',
                  crudo.groupby('anio_encuesta')['FEX.2022'].sum().round(0).a
chequeos.append(('Códigos de ED08 fuera del diccionario oficial (1-19, 99, b
                  sorted(set(crudo.ED08.dropna().unique()) - set(range(1, 20)

# --- Cobertura territorial: ¿aparecen los 17 departamentos + Capital? ----
dptos_observados = sorted(int(d) for d in crudo.DPT0.dropna().unique())
dptos_esperados = set(range(0, 18))
dptos_ausentes = sorted(dptos_esperados - set(dptos_observados))
chequeos.append(('Departamentos observados en la muestra (códigos)', dptos_c
chequeos.append((f'Departamentos NUNCA muestreados en {int(crudo.anio_encues
display(pd.DataFrame(chequeos, columns=['Chequeo', 'Resultado']))

if dptos_ausentes:
    nombres_ausentes = [MAPA_DPT0.get(d, d) for d in dptos_ausentes]
    print(f'\n⚠ {nombres_ausentes} no aparecen en NINGUNO de los años del
    print(' Esto es sistemático, no un error de cruce: la EPHC no releva
    print(' con la periodicidad y desagregación que sí tiene el resto del
    print(' límite de cobertura territorial en la Etapa 1.6 y en la concl
    print(' resultado de este proyecto puede extenderse a la región del C
```

	Chequeo	Resultado
0	Compleitud global	100.00 % de celdas informadas
1	Cobertura temporal	[np.int64(2022), np.int64(2023), np.int64(2024...]
2	Filas duplicadas exactas	0
3	Edad fuera de rango plausible (< 0 o > 110)	0
4	Población total ponderada por año (FEX)	{2022: 5838780, 2023: 5885678, 2024: 5932576, ...}
5	Códigos de ED08 fuera del diccionario oficial ...	[, 1, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19,...]
6	Departamentos observados en la muestra (códigos)	[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13,...]
7	Departamentos NUNCA muestreados en 2022-2025	[16, 17]

⚠ ['Boquerón', 'Alto Paraguay'] no aparecen en NINGUNO de los años del panel.

Esto es sistemático, no un error de cruce: la EPHC no releva esos departamentos

con la periodicidad y desagregación que sí tiene el resto del país. Se declara como

límite de cobertura territorial en la Etapa 1.6 y en la conclusión de la Fase 1: ningún

resultado de este proyecto puede extenderse a la región del Chaco central/norte.

2.7. Evaluación de calidad — lectura

Compleitud. El registro de personas está prácticamente completo en las variables de identificación, zona y departamento; los códigos en blanco de `ED08` / `ED09` / `ED10` no son datos faltantes en sentido estricto, sino personas **fuera del universo de la pregunta** (por ejemplo, adultos a quienes no corresponde preguntarles si asisten a educación media). Ese universo se delimita en la Etapa 3 filtrando por edad.

Consistencia. La estructura de columnas es idéntica en los tres años, lo que evita el problema típico de fuentes administrativas (nombres de campo que cambian entre períodos). El punto de fricción real fue de **formato**: el separador decimal en coma exige `decimal=','` al leer, verificado en la Etapa 2.2.

Exactitud aparente. La suma del factor de expansión por año debe aproximarse a la población total de Paraguay (del orden de 6-7 millones); si ese número no aparece en el orden de magnitud correcto, es señal de que el factor se está leyendo mal (ver nota de la Etapa 2.2).

Actualidad. Los cuatro años están completos y son los más recientes publicados por la DGEEC al momento de la descarga.

Trazabilidad. La fuente (DGEEC, EPHC anual) y el diccionario oficial de variables permiten auditar cada código contra la documentación metodológica publicada.

2.8. Selección justificada

Elemento	Decisión	Justificación	Objetivo vinculado
Sección Educación (ED01 – ED11GH1A)	Se conserva parcialmente (ED03 , ED08 , ED09 , ED10)	Son las variables de asistencia, sector y motivo que responden la pregunta	OE1–OE4
ED0504 (nivel más alto aprobado) y ED06C (título obtenido)	Se descarta	Describen la trayectoria educativa completa, no la asistencia actual ni el motivo de inasistencia	—
ED11F1 , ED11GH1 (merienda/almuerzo escolar)	Se descarta de esta fase	Es un programa social distinto al fenómeno de inasistencia; podría explorarse como variable de control en la Fase 3	(posible OE4)
Todas las secciones de empleo, salud e ingresos (A01 – C...)	Se descarta	Fuera del alcance declarado en la Etapa 1.6; ninguna hipótesis del proyecto las requiere	—
Personas fuera de 12–17 años	Se descarta para el análisis principal	La pregunta está acotada a esa edad teórica (Etapa 1.6); se conserva el archivo completo por si se decide ampliar el rango más adelante	OE1–OE4

2.9. Documentación de la fuente

Ítem	Valor
Fuente	Dirección General de Estadística, Encuestas y Censos (DGEEC), Paraguay
Encuesta	Encuesta Permanente de Hogares Continua (EPHC), rondas anuales 2022, 2023, 2024 y 2025
Archivos	REG02_EPHC_ANUAL_2022.csv ... REG02_EPHC_ANUAL_2025.csv
Diccionario de variables	diccionario_EPHC_ANUAL_2023.xls (hoja EPHC 2023)
Licencia	Microdatos de uso público de la DGEEC

Ítem	Valor
Unidad de medida del factor de expansión	Personas representadas (FEX.2022 en 2022–2024; FACTOR en 2025)
Responsable de la descarga	Iván Paredes (archivos colocados en <code>data/raw/</code> por el grupo)
Fecha de descarga	12 de septiembre de 2026

Etapas 3 — Limpieza y transformación

Regla no negociable: toda transformación es reproducible por código desde los archivos originales. Nada se edita a mano. Cada decisión queda registrada en la bitácora (sección 3.6).

```
In [9]: # =====
# Bitácora de limpieza
# =====
class Bitacora:
    def __init__(self):
        self.registros = []
    def anotar(self, etapa, decision, afectados, fundamento, antes=None, des
        self.registros.append({'n': len(self.registros)+1, 'etapa': etapa, '
                                'registros_afectados': afectados, 'filas_ante
                                'filas_despues': despues, 'fundamento': funda
        print(f'[{len(self.registros):02d}] {etapa} – {decision} ({afectados
    def tabla(self):
        return pd.DataFrame(self.registros)

bitacora = Bitacora()
df = crudo.copy()
FILAS_INICIALES = len(df)
print(f'Punto de partida: {FILAS_INICIALES:,} filas (todas las personas, toc
```

Punto de partida: 233,595 filas (todas las personas, todas las edades, panel completo)

```
In [10]: # =====
# 3.1 – Normalización de tipos y de categorías
# =====

# Renombrado a nombres de trabajo legibles (se conserva la equivalencia en e
df = df.rename(columns={
    'AÑO': 'anio_dato', 'DPT0': 'cod_departamento', 'AREA': 'cod_zona', 'P02
    'P06': 'cod_sexo', 'ED08': 'cod_asistencia', 'ED09': 'cod_sector', 'ED10
    'FEX.2022': 'factor_expansion', 'FACTOR': 'factor_expansion',
})
bitacora.anotar('3.1 Tipos', 'Renombrado de columnas a nombres de trabajo le
                'Los códigos crudos (P02, ED08, ...) no son autoexplicativos;
```

```

for col in ['cod_departamento', 'cod_zona', 'cod_sexo', 'cod_asistencia', 'c
df[col] = pd.to_numeric(df[col], errors='coerce')

df['zona'] = df.cod_zona.map(MAPA_AREA)
df['sexo'] = df.cod_sexo.map(MAPA_SEX0)
df['departamento'] = df.cod_departamento.map(MAPA_DPT0)
df['sector'] = df.cod_sector.map(MAPA_ED09_SECTOR)
df['motivo_inasistencia'] = df.cod_motivo.map(MAPA_ED10_MOTIVO)
bitacora.anoar('3.1 Tipos', 'Mapeo de códigos numéricos a etiquetas legible
len(df), 'Los códigos numéricos no son interpretables sin el

n_sin_dpto = int(df.departamento.isna().sum())
if n_sin_dpto:
    print(f'⚠️ {n_sin_dpto} filas con código de departamento fuera de 0-17 (

display(df[['anio_encuesta', 'edad', 'zona', 'sexo', 'departamento', 'sector

```

[01] 3.1 Tipos – Renombrado de columnas a nombres de trabajo legibles (16)
[02] 3.1 Tipos – Mapeo de códigos numéricos a etiquetas legibles (zona, sex
o, departamento, sector, motivo) (233,595)

	anio_encuesta	edad	zona	sexo	departamento	sector	cod_asistencia
0	2022	74	Urbana	Mujer	Capital	NaN	NaN
1	2022	18	Urbana	Mujer	Capital	Oficial	3.000
2	2022	56	Urbana	Hombre	Capital	NaN	NaN
3	2022	20	Urbana	Hombre	Capital	Privado	16.000
4	2022	69	Urbana	Mujer	Capital	NaN	NaN

```

In [11]: # =====
# 3.2 – Delimitación del universo de análisis: personas de 12 a 17 años
# =====
antes = len(df)
n_fuera_edad = int((~df.edad.between(EDAD_MIN, EDAD_MAX)).sum())
panel = df[df.edad.between(EDAD_MIN, EDAD_MAX)].copy()
bitacora.anoar('3.2 Universo', f'Filtro a edad {EDAD_MIN}-{EDAD_MAX} años (
n_fuera_edad,
'La pregunta de investigación está acotada a la edad teórica
'incluir otras edades mezclaría fenómenos distintos (deserci
antes, len(panel))

n_dpto_faltante = int(panel.departamento.isna().sum())
if n_dpto_faltante:
    antes = len(panel)
    panel = panel[panel.departamento.notna()].copy()
    bitacora.anoar('3.2 Universo', 'Eliminación de filas sin departamento m
'Código de departamento fuera del rango documentado (0-1
antes, len(panel))

print(f'\nUniverso de análisis (12-17 años): {len(panel):,} personas encuest
print(f'Población representada (ponderada): {panel.factor_expansion.sum():,}

```

[03] 3.2 Universo – Filtro a edad 12–17 años (universo declarado en Etapa 1.6) (209,279)

Universo de análisis (12–17 años): 24,316 personas encuestadas
Población representada (ponderada): 2,460,607 personas

```
In [12]: # =====
# 3.3 – Construcción de la variable de asistencia y de inasistencia
# =====
panel['asiste_actualmente'] = (panel.cod_asistencia != COD_NO_ASISTE).astype(int)
panel['no_asiste'] = 1 - panel['asiste_actualmente']
bitacora.anostrar('3.3 Derivadas', f'Creación de «asiste_actualmente» / «no_asiste» a partir del código 19 (24,316)')
len(panel), 'ED08 trae 19 códigos de nivel/modalidad para que sea binario porque la pregunta de investigación es sobre inasistencia'

# El motivo (ED10) sólo tiene sentido para quienes no asisten; se documenta con motivo
con_motivo = panel[panel.no_asiste == 1]
n_motivo_valido = int(con_motivo.motivo_inasistencia.notna().sum())
print(f'Personas que NO asisten (muestra): {len(con_motivo):,}')
print(f'De ellas, con motivo válido registrado: {n_motivo_valido:,} '
      f'({100*n_motivo_valido/max(len(con_motivo),1):.1f} %)')
```

[04] 3.3 Derivadas – Creación de «asiste_actualmente» / «no_asiste» a partir del código 19 (24,316)
Personas que NO asisten (muestra): 1,912
De ellas, con motivo válido registrado: 1,912 (100.0 %)

```
In [13]: # =====
# 3.4 – Valores atípicos e inconsistencias
# =====
# El factor de expansión debe ser positivo; un valor negativo o cero sería un error
incons = [
    ('factor_expansion <= 0', int((panel.factor_expansion <= 0).sum())),
    ('edad fuera de 12-17 (control post-filtro)', int((~panel.edad.between(12, 17)).sum())),
    ('cod_sexo fuera de {1, 6}', int((~panel.cod_sexo.isin([1, 6])).sum())),
]
display(pd.DataFrame(incons, columns=['Chequeo', 'Registros']))

# Distribución del factor de expansión (para detectar valores extremos que podrían sesgar los resultados)
display(panel.factor_expansion.describe(percentiles=[.01, .05, .5, .95, .99]))

bitacora.anostrar('3.4 Atípicos', 'Factores de expansión extremos CONSERVADOS')
bitacora.anostrar('3.4 Atípicos', 'Los pesos muestrales grandes son parte del diseño (representación de la población) y no son errores de carga y eliminarlos introduciría sesgo, por lo que se conservan')
bitacora.anostrar('3.4 Atípicos', 'Se conservan los pesos muestrales grandes porque son parte del diseño y no son errores de carga')
bitacora.anostrar('3.4 Atípicos', 'Se conservan los pesos muestrales grandes porque son parte del diseño y no son errores de carga')
bitacora.anostrar('3.4 Atípicos', 'Se conservan los pesos muestrales grandes porque son parte del diseño y no son errores de carga')
```

	Chequeo	Registros
0	factor_expansion <= 0	0
1	edad fuera de 12-17 (control post-filtro)	0
2	cod_sexo fuera de {1, 6}	0

```

count    24,316.000
mean      101.193
std       65.252
min       11.183
1%        23.026
5%        32.126
50%       86.474
95%      221.659
99%      330.089
max       985.537

```

Name: factor_expansion, dtype: float64

[05] 3.4 Atípicos – Factores de expansión extremos CONSERVADOS (0)

```

In [14]: # =====
# 3.5 – Funciones de estadística ponderada (usadas en toda la Etapa 4 y 5)
# =====

def tasa_ponderada(df, col_indicador, col_peso='factor_expansion') -> float:
    """% ponderado de un indicador 0/1, expandido a la población representada"""
    return 100 * np.average(df[col_indicador], weights=df[col_peso])

def tabla_tasas_por_grupo(df, col_grupo, col_indicador='no_asiste', col_peso='factor_expansion'):
    def _agg(g):
        return pd.Series({
            'n_muestral': len(g),
            'poblacion_ponderada': g[col_peso].sum(),
            'tasa_%': tasa_ponderada(g, col_indicador, col_peso),
        })
    return df.groupby(col_grupo).apply(_agg).sort_values('tasa_%', ascending=False)

def tabla_contingencia_ponderada(df, fila, columna, col_peso='factor_expansion'):
    """Tabla de doble entrada con SUMA de pesos (no conteo de filas)."""
    return df.pivot_table(index=fila, columns=columna, values=col_peso, aggfunc='sum')

print('Funciones de estadística ponderada listas: tasa_ponderada(), tabla_tasas_por_grupo(), tabla_contingencia_ponderada()')
print('\nVerificación: tasa nacional de inasistencia (12-17), ponderada, por año de encuesta:')
display(tabla_tasas_por_grupo(panel, 'anio_encuesta').round(2))

```

Funciones de estadística ponderada listas: tasa_ponderada(), tabla_tasas_por_grupo(), tabla_contingencia_ponderada()

Verificación: tasa nacional de inasistencia (12-17), ponderada, por año de encuesta:

	n_muestral	poblacion_ponderada	tasa_%
anio_encuesta			
2022	6,618.000	618,044.980	8.480
2023	6,026.000	614,894.160	7.550
2024	5,914.000	613,581.410	7.410
2025	5,758.000	614,086.000	6.300

```
In [15]: # =====
# 3.6 – Bitácora y exportación del dataset final
# =====
tabla_bitacora = bitacora.tabla()
display(tabla_bitacora)
tabla_bitacora.to_csv(DIR_TAB / 'bitacora_limpieza.csv', index=False)

COLS_FINALES = ['anio_encuesta', 'UPM', 'NVIVI', 'NHOGA', 'L02', 'edad', 'se',
                'sector', 'asiste_actualmente', 'no_asiste', 'motivo_inasist
final = panel[COLS_FINALES].copy()

print(f'Filas iniciales (todas las edades): {FILAS_INICIALES:,}')
print(f'Filas finales (universo 12–17 años)      : {len(final):,}')
print(f'Población representada (ponderada)       : {final.factor_expansi

try:
    ruta = DIR_PROC / 'dataset_fase1.parquet'; final.to_parquet(ruta, index=
except Exception:
    ruta = DIR_PROC / 'dataset_fase1.csv'; final.to_csv(ruta, index=False, e
print('Dataset limpio guardado en:', ruta.relative_to(RAIZ))

META_FINAL = {'anio_encuesta': ('entero', 'Año de la ronda EPHC (2022–2025)')

dicc_final = completar_diccionario(diccionario_datos(final), META_FINAL)
dicc_final.to_csv(DIR_TAB / 'diccionario_datos_final.csv', index=False)
display(dicc_final)
```

	n	etapa	decision	registros_afectados	filas_antes	filas_despues
0	1	3.1 Tipos	Renombrado de columnas a nombres de trabajo le...	16	NaN	NaN
1	2	3.1 Tipos	Mapeo de códigos numéricos a etiquetas legible...	233595	NaN	NaN
2	3	3.2 Universo	Filtro a edad 12-17 años (universo declarado e...	209279	233,595.000	24,316.000
3	4	3.3 Derivadas	Creación de «asiste_actualmente» / «no_asiste»...	24316	NaN	NaN
4	5	3.4 Atípicos	Factores de expansión extremos CONSERVADOS	0	NaN	NaN

Filas iniciales (todas las edades): 233,595

Filas finales (universo 12-17 años) : 24,316

Población representada (ponderada) : 2,460,607

Dataset limpio guardado en: data/processed/dataset_fase1.parquet

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos
0	anio_encuesta	int64	entero	Año de la ronda EPHC (2022–2025)	año	4
1	UPM	int64	entero	Unidad primaria de muestreo	código	1817
2	NVIVI	int64	entero	Número de vivienda dentro de la UPM	código	138
3	NHOGA	int64	entero	Número de hogar dentro de la vivienda	código	3
4	L02	int64	entero	Número de línea / persona dentro del hogar	código	20
5	edad	int64	entero	Edad en años cumplidos (universo 12–17)	años	6
6	sexo	str	categoría nominal	Sexo declarado (Hombre / Mujer)	categoría	2
7	zona	str	categoría nominal	Zona de residencia (Urbana / Rural)	categoría	2
8	departamento	str	categoría nominal	Departamento de residencia (16 dptos. relevados)	categoría	16
9	sector	str	categoría nominal	Sector de la institución a la que asiste; nulo...	categoría	4
10	asiste_actualmente	int64	binaria	1 si asiste a educación formal; 0 si no asiste...	0/1	2
11	no_asiste	int64	binaria	Variable objetivo: 1 = no asiste; 0 = asiste	0/1	2

	campo	tipo_detectado	tipo_correcto	descripcion	unidad	n_unicos
12	motivo_inasistencia	str	categorica nominal	Motivo declarado (ED10); nulo si asiste	categoría	17
13	factor_expansion	float64	continuo	Factor de expansión (FEX.2022 / FACTOR); ponde...	personas	11476

Etapas 4 — Análisis univariado y bivariado

Nota metodológica que atraviesa toda esta etapa: por tratarse de una encuesta muestral, todas las frecuencias, tasas y proporciones se calculan **ponderadas por factor_expansion**. Los conteos simples de filas (`n_muestral`) se reportan aparte porque indican la precisión de la estimación, no el tamaño real de la población.

4.1. Univariado — variable numérica (edad)

```
In [16]: # =====
# Estadísticos de la edad (única variable numérica sustantiva del panel)
# =====
def resumen_numerico_ponderado(df, col, peso='factor_expansion'):
    valores, pesos = df[col].values, df[peso].values
    media = np.average(valores, weights=pesos)
    varianza = np.average((valores - media)**2, weights=pesos)
    orden = np.argsort(valores)
    v_ord, p_ord = valores[orden], pesos[orden]
    cum = np.cumsum(p_ord) / p_ord.sum()
    percentil = lambda q: v_ord[np.searchsorted(cum, q)]
    return {
        'n': len(df), 'media_ponderada': media, 'desvio_ponderado': np.sqrt(
            varianza), 'p5': percentil(.05), 'p25': percentil(.25), 'mediana': percentil(.5),
            'p75': percentil(.75), 'p95': percentil(.95), 'min': valores.min(),
            'asimetria_muestral': stats.skew(valores), 'curtosis_muestral': stats.kurtosis(valores)
    }


resumen_edad = resumen_numerico_ponderado(final, 'edad')
display(pd.Series(resumen_edad).to_frame('edad (12-17 años)'))

fig, ax = plt.subplots(figsize=(9, 4.5))
sns.histplot(data=final, x='edad', weights='factor_expansion', bins=6, discrete=True)
ax.set_title('Distribución ponderada de la edad en el universo de análisis (ED10)')
ax.set_xlabel('Edad (años)'); ax.set_ylabel('Población representada (personas)')
```



```
plt.savefig(DIR_FIG / '01_univariado_edad.png'); plt.show()
print('Cada edad pesa entre 16,3 % y 17,2 %. En 2024 hay menos casos de 17 a
```

edad (12-17 años)	
n	24,316.000
media_ponderada	14.480
desvio_ponderado	1.709
p5	12.000
p25	13.000
mediana	14.000
p75	16.000
p95	17.000
min	12.000
max	17.000
asimetria_muestral	0.026
curtosis_muestral	-1.273



Cada edad pesa entre 16,3 % y 17,2 %. En 2024 hay menos casos de 17 años (894); 2025 recupera un poco (942).

4.2. Univariado — variables categóricas y concentración

```
In [17]: # =====
# Frecuencias ponderadas y concentración
# =====
```

```

VARS_CAT = ['zona', 'sexo', 'departamento', 'sector', 'anio_encuesta']
for c in VARS_CAT:
    tab = (final.groupby(c)['factor_expansion'].sum().sort_values(ascending=
    tab_pct = (100 * tab / tab.sum()).round(2)
    resumen = pd.concat([tab.round(0).rename('poblacion_ponderada'), tab_pct
    resumen['acumulada_%'] = resumen['%'].cumsum().round(2)
    print(f'\n=== {c} - {tab.size} categorías ===')
    display(resumen)

```

=== zona – 2 categorías ===

	poblacion_ponderada	%	acumulada_%
zona			
Urbana	1,500,499.000	60.980	60.980
Rural	960,108.000	39.020	100.000

=== sexo – 2 categorías ===

	poblacion_ponderada	%	acumulada_%
sexo			
Hombre	1,235,036.000	50.190	50.190
Mujer	1,225,571.000	49.810	100.000

=== departamento – 16 categorías ===

	poblacion_ponderada	%	acumulada_%
departamento			
Central	720,241.000	29.270	29.270
Alto Paraná	304,171.000	12.360	41.630
Caaguazú	217,342.000	8.830	50.460
Itapúa	200,217.000	8.140	58.600
San Pedro	167,025.000	6.790	65.390
Capital	147,746.000	6.000	71.390
Cordillera	114,103.000	4.640	76.030
Concepción	97,388.000	3.960	79.990
Paraguarí	84,023.000	3.410	83.400
Canindeyú	83,691.000	3.400	86.800
Guairá	77,825.000	3.160	89.960
Caazapá	74,031.000	3.010	92.970
Amambay	64,907.000	2.640	95.610
Misiones	42,834.000	1.740	97.350
Presidente Hayes	38,462.000	1.560	98.910
Ñeembucú	26,602.000	1.080	99.990


=== sector – 4 categorías ===

	poblacion_ponderada	%	acumulada_%
sector			
Oficial	1,860,576.000	81.950	81.950
Privado	238,948.000	10.520	92.470
Privado subvencionado	170,370.000	7.500	99.970
NR	511.000	0.020	99.990

=== anio_encuesta – 4 categorías ===

	poblacion_ponderada	%	acumulada_%
anio_encuesta			
2022	618,045.000	25.120	25.120
2023	614,894.000	24.990	50.110
2025	614,086.000	24.960	75.070
2024	613,581.000	24.940	100.010

```
In [18]: # =====
# Gráfico univariado de zona y sector (ponderados)
# =====
fig, axes = plt.subplots(1, 2, figsize=(12, 4.8))
for ax, col in zip(axes, ['zona', 'sector']):
    tab = final.groupby(col)['factor_expansion'].sum().sort_values(ascending=True)
    ax.bar(tab.index.astype(str), tab.values, color='#4c72b0')
    ax.set_title(f'Población de 12-17 años por {col} (ponderada)')
    ax.set_ylabel('Personas representadas'); ax.tick_params(axis='x', rotation=45)
plt.tight_layout(); plt.savefig(DIR_FIG / '02_univariado_categoricas.png');
```



4.3. Bivariado — la variable central: tasa de inasistencia por grupo

```
In [19]: # =====
# Tasa de inasistencia ponderada por zona, sexo y año
# =====
for col in ['zona', 'sexo', 'anio_encuesta']:
    print(f'\n=== Tasa de inasistencia (12-17) según {col} ===')
    display(tabla_tasas_por_grupo(final, col).round(2))
```

=== Tasa de inasistencia (12-17) según zona ===

	n_muestral	poblacion_ponderada	tasa_%
zona			
Rural	11,242.000	960,107.800	11.430
Urbana	13,074.000	1,500,498.750	4.880

=== Tasa de inasistencia (12-17) según sexo ===

	n_muestral	poblacion_ponderada	tasa_%
sexo			
Hombre	12,408.000	1,235,035.530	8.350
Mujer	11,908.000	1,225,571.010	6.510

=== Tasa de inasistencia (12-17) según anio_encuesta ===

	n_muestral	poblacion_ponderada	tasa_%
anio_encuesta			
2022	6,618.000	618,044.980	8.480
2023	6,026.000	614,894.160	7.550
2024	5,914.000	613,581.410	7.410
2025	5,758.000	614,086.000	6.300


```
In [20]: # =====
# Bivariado numérica-categórica: ¿la edad se asocia con la inasistencia?
# =====
print('Edad media ponderada, según asiste / no asiste:')
display(final.groupby('no_asiste').apply(
    lambda g: pd.Series({'edad_media_pond': np.average(g.edad, weights=g.fac
    ))

fig, ax = plt.subplots(figsize=(9, 5))
sns.violinplot(data=final, x='no_asiste', y='edad', ax=ax, inner='quartile',
ax.set_xticklabels(['Asiste', 'No asiste'])
ax.set_title('Distribución de edad según condición de asistencia')
ax.set_xlabel(''); ax.set_ylabel('Edad (años)')
plt.savefig(DIR_FIG / '03_edad_por_asistencia.png'); plt.show()
print('Los que no asisten son más grandes (15,8 vs 14,4). Pooled: 1,1 % a lo
```

Edad media ponderada, según asiste / no asiste:

	edad_media_pond	n
no_asiste		
0	14.376	22,404.000
1	15.778	1,912.000

```
/var/folders/lp/flhffk1951v91kr4yx185z3m0000gn/T/ipykernel_63342/3507224591.
py:11: UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator. Otherwise, ticks m
ay be mislabeled.
    ax.set_xticklabels(['Asiste', 'No asiste'])
```



Los que no asisten son más grandes (15,8 vs 14,4 años). La tasa va de 1,3 % a los 12 a 19,1 % a los 17: se concentra al final del rango, cuando toca educación media.

4.4. Bivariado — categórica frente a categórica (tablas de contingencia ponderadas)

```
In [21]: # =====
# Tabla de contingencia ponderada: zona × sector (entre quienes asisten)
# =====
asisten = final[final.asiste_actualmente == 1]
cont = tabla_contingencia_ponderada(asisten, 'zona', 'sector')
print('--- Población ponderada que asiste, por zona y sector ---'); display(cont)
print('--- % por fila (dentro de cada zona) ---')
display((100 * cont.div(cont.sum(axis=1), axis=0)).round(2))

chi2, p, gl, esp = stats.chi2_contingency(cont)
v = np.sqrt(chi2 / (cont.values.sum() * (min(cont.shape)-1)))
print(f'\nExploratorio (sobre frecuencias ponderadas, no el n muestral real)
      f'χ² = {chi2:,.1f} | p = {p:.4g} | V de Cramér = {v:.3f}')
print('⚠ Este chi-cuadrado usa la población EXPANDIDA como si fuera el tamaño
      'artificialmente la significancia. Es válido para describir la asociación
      'contraste formal de la Fase 2 deberá ejecutarse sobre el n muestral real')
```

--- Población ponderada que asiste, por zona y sector ---

sector	NR	Oficial	Privado	Privado subvencionado
zona				
Rural	0.000	788,608.000	29,771.000	30,374.000
Urbana	511.000	1,071,968.000	209,177.000	139,996.000

--- % por fila (dentro de cada zona) ---

sector	NR	Oficial	Privado	Privado subvencionado
zona				
Rural	0.000	92.910	3.510	3.580
Urbana	0.040	75.400	14.710	9.850

Exploratorio (sobre frecuencias ponderadas, no el n muestral real): $\chi^2 = 11$
1,434.8 | p = 0 | V de Cramér = 0.222

⚠ Este chi-cuadrado usa la población EXPANDIDA como si fuera el tamaño muestral real, lo que infla artificialmente la significancia. Es válido para describir la asociación (V de Cramér), pero el contraste formal de la Fase 2 deberá ejecutarse sobre el n muestral real o con métodos de encuestas complejas.

```
In [22]: # =====  
# Tabla de contingencia ponderada: zona x motivo de inasistencia  
# =====  
no_asisten = final[final.no_asiste == 1].dropna(subset=['motivo_inasistencia'])  
cont_motivo = tabla_contingencia_ponderada(no_asisten, 'motivo_inasistencia')  
cont_motivo['total'] = cont_motivo.sum(axis=1)  
cont_motivo = cont_motivo.sort_values('total', ascending=False).drop(columns='total')  
display(cont_motivo.round(0))  
print('\n--- % de cada motivo dentro de cada zona ---')  
display((100 * cont_motivo.div(cont_motivo.sum(axis=0), axis=1)).round(1))
```

motivo_inasistencia	zona	Rural	Urbana
Sin recursos en el hogar		29,554.000	16,814.000
No quiere estudiar		23,141.000	19,347.000
Motivos familiares		21,728.000	15,678.000
Necesidad de trabajar		10,495.000	8,251.000
No existe institución cercana		11,623.000	421.000
Requiere educación especial		3,732.000	3,431.000
Por enfermedad		2,316.000	3,142.000
Otra razón		1,051.000	4,235.000
Considera que terminó los estudios		2,908.000	0.000
Muy costosos materiales y matrículas		1,496.000	237.000
Asiste a formación profesional/vocacional		59.000	1,324.000
Institución cercana muy mala		792.000	224.000
Institución no ofrece escolaridad completa		553.000	92.000
El docente no asiste con regularidad		147.000	0.000
El centro educativo cerró		105.000	0.000
Debe hacer labores en el hogar		0.000	71.000

--- % de cada motivo dentro de cada zona ---


	zona	Rural	Urbana
motivo_inasistencia			
Sin recursos en el hogar		26.900	22.900
No quiere estudiar		21.100	26.400
Motivos familiares		19.800	21.400
Necesidad de trabajar		9.600	11.300
No existe institución cercana		10.600	0.600
Requiere educación especial		3.400	4.700
Por enfermedad		2.100	4.300
Otra razón		1.000	5.800
Considera que terminó los estudios		2.700	0.000
Muy costosos materiales y matrículas		1.400	0.300
Asiste a formación profesional/vocacional		0.100	1.800
Institución cercana muy mala		0.700	0.300
Institución no ofrece escolaridad completa		0.500	0.100
El docente no asiste con regularidad		0.100	0.000
El centro educativo cerró		0.100	0.000
Debe hacer labores en el hogar		0.000	0.100

4.5. Análisis temporal (2022–2025)

```
In [23]: # =====
# Evolución de la tasa de inasistencia por año y zona
# =====
evo = final.groupby(['anio_encuesta', 'zona']).apply(
    lambda g: tasa_ponderada(g, 'no_asiste')).unstack()
display(evo.round(2))
evo.to_csv(DIR_TAB / 'serie_temporal_tasa_inasistencia.csv')

fig, ax = plt.subplots(figsize=(9, 5))
for col in evo.columns:
    ax.plot(evo.index, evo[col], marker='o', lw=2, label=col)
ax.set_title('Evolución de la tasa de inasistencia escolar (12–17 años) según año de la encuesta')
ax.set_xlabel('Año de la encuesta'); ax.set_ylabel('Tasa de inasistencia (%)')
ax.set_xticks(evo.index); ax.legend(title='Zona')
plt.savefig(DIR_FIG / '04_evolucion_tasa.png'); plt.show()
```

	zona	Rural	Urbana
anio_encuesta			
	2022	12.840	5.240
	2023	11.360	4.850
	2024	10.800	5.100
	2025	10.400	4.420




Etapa 5 — Análisis descriptivo y exploratorio

Mínimo **ocho visualizaciones distintas**, cada una con título descriptivo, ejes rotulados con unidades, leyenda cuando corresponda, escala que no distorsione y una **interpretación escrita de una a tres oraciones inmediatamente debajo**. Todas las cifras están ponderadas por el factor de expansión.


```
In [24]: # === G1 · Serie temporal – tasa de inasistencia por zona (2022-2025) =====
fig, ax = plt.subplots(figsize=(10, 5))
for col in evo.columns:
    ax.plot(evo.index, evo[col], marker='o', lw=2.2, label=col)
ax.set_title('G1 · Evolución de la tasa de inasistencia escolar (12-17 años)')
ax.set_xlabel('Año de la encuesta'); ax.set_ylabel('Tasa de inasistencia (%,'
```

```
ax.set_xticks(evo.index); ax.legend(title='Zona')
plt.savefig(DIR_FIG / 'G1_serie_tasa_zona.png'); plt.show()
```



En los cuatro años la rural queda arriba: 12,8 % vs 5,2 % en 2022, y 10,4 % vs 4,4 % en 2025. La brecha se achica (7,6 → ~6 puntos) porque baja el campo, no porque suba la ciudad. En 2025 sigue siendo más del doble. Sumar 2025 no da vuelta el patrón; lo que hace es confirmar que la caída rural continúa.

```
In [25]: # === G2 · Histograma – distribución de edad en el universo de análisis ===
fig, ax = plt.subplots(figsize=(9, 4.8))
sns.histplot(data=final, x='edad', weights='factor_expansion', bins=6, discr
ax.set_title('G2 · Distribución ponderada de la edad, personas de 12 a 17 añ
ax.set_xlabel('Edad (años)'); ax.set_ylabel('Población representada (persona
plt.savefig(DIR_FIG / 'G2_histograma_edad.png'); plt.show()
```




Cada edad de 12 a 17 pesa entre 16,3 % y 17,2 %. No hay un hueco raro. El año con menos 17 años en muestra sigue siendo 2024 (894); 2025 recupera un poco (942). Para la tasa nacional no cambia el dibujo.

```
In [26]: # === G3 · Diagrama de caja/violín – edad según condición de asistencia ===
fig, ax = plt.subplots(figsize=(8, 5))
sns.violinplot(data=final, x='no_asiste', y='edad', ax=ax, inner='quartile',
ax.set_xticklabels(['Asiste', 'No asiste'])
ax.set_title('G3 · Distribución de edad según condición de asistencia actual
ax.set_xlabel(''); ax.set_ylabel('Edad (años)')
plt.savefig(DIR_FIG / 'G3_edad_asistencia.png'); plt.show()
```

```
/var/folders/lp/flhffk1951v91kr4yx185z3m0000gn/T/ipykernel_63342/3570236787.
py:4: UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator. Otherwise, ticks m
ay be mislabeled.
```


```
ax.set_xticklabels(['Asiste', 'No asiste'])
```



Los que no asisten son más grandes (media 15,8 vs 14,4). En el pooled 2022–2025 la tasa va de 1,1 % a los 12 a 18,5 % a los 17 (en 2025 esos extremos son 0,7 % y 16,5 %, más bajos, pero la escalera es la misma). El problema se ve al final del rango, cuando toca media.

```
In [27]: # === G4 · Barras comparativas – tasa de inasistencia por departamento ===
tab_dpto = tabla_tasas_por_grupo(final, 'departamento')
fig, ax = plt.subplots(figsize=(10, 7))
colores = ['#c44e52' if n < 150 else '#4c72b0' for n in tab_dpto['n_muestral']]
ax.barh(tab_dpto.index[::-1], tab_dpto['tasa_%'][:,::-1], color=colores[:,::-1])
ax.axvline(tasa_ponderada(final, 'no_asiste'), color='black', ls='--', lw=1,
           label=f'Media nacional ({tasa_ponderada(final, "no_asiste"):.1f})')
ax.set_title('G4 · Tasa de inasistencia escolar (12–17 años) por departamento')
ax.set_xlabel('Tasa de inasistencia (% ponderada)'); ax.set_ylabel('Departamento')
ax.legend()
ax.text(.98, .02, 'En rojo: departamentos con n muestral < 150 (estimación n')
        transform=ax.transAxes, ha='right', fontsize=8, style='italic')
plt.tight_layout(); plt.savefig(DIR_FIG / 'G4_barras_departamento.png'); plt
display(tab_dpto.round(2))
```

G4 · Tasa de inasistencia escolar (12-17 años) por departamento, 2022-2025




	n_muestral	poblacion_ponderada	tasa_%
departamento			
Itapúa	2,144.000	200,217.450	11.920
San Pedro	1,699.000	167,025.030	11.800
Canindeyú	1,367.000	83,690.550	11.640
Guairá	969.000	77,824.790	11.210
Amambay	1,138.000	64,906.960	10.370
Caaguazú	1,612.000	217,341.500	10.300
Alto Paraná	2,886.000	304,170.980	8.630
Caazapá	1,422.000	74,031.210	8.600
Concepción	1,039.000	97,387.620	7.870
Presidente Hayes	902.000	38,461.540	7.690
Cordillera	1,282.000	114,103.020	6.560
Misiones	1,045.000	42,834.130	5.200
Ñeembucú	618.000	26,601.850	4.470
Central	3,779.000	720,241.150	4.310
Paraguarí	963.000	84,022.630	4.270
Capital	1,451.000	147,746.130	2.050

En el pooled 2022–2025 los más altos son Itapúa (11,9 %), San Pedro (11,8 %) y Canindeyú (11,6 %). Capital sigue último (2,1 %), con n = 1.451. El promedio del país baja a 7,4 %. Ojo con el recorte 2025 solo: ese año el máximo es Canindeyú (11,7 %) e Itapúa/San Pedro caen a ~9 %; Misiones y Paraguarí suben. El ranking del pooled no es una foto de 2025. El n más chico sigue siendo Ñeembucú (618 en el pooled; 153 en 2025: ese año no hay que leerlo fino).

```
In [28]: # === G5 · Mapa de calor – motivo de inasistencia según zona =====
cont_motivo_pct = (100 * cont_motivo.div(cont_motivo.sum(axis=0), axis=1))
fig, ax = plt.subplots(figsize=(8, 7))
sns.heatmap(cont_motivo_pct, annot=True, fmt='.1f', cmap='Reds', ax=ax,
            cbar_kws={'label': '% dentro de la zona'})
ax.set_title('G5 · Motivo de inasistencia declarado, según zona (% dentro de
ax.set_xlabel('Zona'); ax.set_ylabel('Motivo declarado')
plt.tight_layout(); plt.savefig(DIR_FIG / 'G5_heatmap_motivo_zona.png'); plt
```

G5 · Motivo de inasistencia declarado, según zona (% dentro de cada zona)




En el pooled, "sin recursos" sigue primero en las dos zonas, pero ya no empatados: 26,9 % rural vs 22,9 % urbana. "No hay institución cerca" sigue siendo del campo (10,6 % vs 0,6 %). En la ciudad pesan más "no quiere estudiar" (26,4 % vs 21,1 %).

2025 mueve esto. Ese año, en el país gana "no quiere estudiar" (27,1 %) y "sin recursos" cae a 16,9 %. En urbana 2025 "sin recursos" queda en 9,7 % y "no quiere estudiar" en 30 %; "no hay institución cerca" en ciudad es 0 %. La idea que se lleva a Fase 2 ya no es "el motivo económico es igual en los dos lados", sino: la oferta chica es rural; el mix plata vs no querer seguir **cambia con el año y con la zona.**

```
In [29]: # === G6 · Barras – top motivos de inasistencia a nivel nacional ===
motivo_nac = (no_asisten.groupby('motivo_inasistencia')['factor_expansion'].
              .sort_values(ascending=False))
motivo_nac_pct = (100 * motivo_nac / motivo_nac.sum())
fig, ax = plt.subplots(figsize=(10, 6))
ax.barh(motivo_nac_pct.index[::-1], motivo_nac_pct.values[::-1], color='#dd8888')
ax.set_title('G6 · Motivos declarados de inasistencia escolar, 12-17 años (rural vs urbana)')
ax.set_xlabel('Participación en el total de inasistentes (% , ponderada)');
plt.tight_layout(); plt.savefig(DIR_FIG / 'G6_motivos_nacional.png'); plt.show()
```



G6 · Motivos declarados de inasistencia escolar, 12-17 años (nacional, 2022-2025)



En 2022–2025 juntos, tres respuestas se llevan ~69 %: sin recursos (25,3 %), no quiere estudiar (23,2 %) y familia (20,4 %). Trabajar 10,2 %; no hay institución cerca 6,6 %.


Eso es el pooled. En 2025 el orden no es el mismo: primero no quiere estudiar (27,1 %), después familia (20,7 %) y recién tercero sin recursos (16,9 %). No se puede hablar de “el” motivo nacional sin decir de qué años. Para política: transferencias siguen importando, pero 2025 avisa que motivación/permanencia ganó peso, sobre todo en ciudad.

```
In [30]: # === G7 · Barras agrupadas – sector educativo por zona (entre quienes asist
cont_pct = (100 * cont.div(cont.sum(axis=1), axis=0))
ax = cont_pct.plot(kind='bar', figsize=(9, 5.5), width=.7)
ax.set_title('G7 · Composición por sector educativo, según zona (entre quier
ax.set_xlabel('Zona'); ax.set_ylabel('% dentro de la zona (ponderado)')
ax.legend(title='Sector'); plt.xticks(rotation=0)
plt.tight_layout(); plt.savefig(DIR_FIG / 'G7_sector_por_zona.png'); plt.shc
```



De los que asisten, en el campo el 93 % está en oficial (privado + subvencionado ~7 %). En la ciudad el oficial es 75 % y hay un 25 % no estatal. 2025 no cambia eso (92 % / 76 %). Si en el pueblo no hay colegio cerca, tampoco hay uno privado al lado.

```
In [31]: # === G8 · Dispersión – tasa de inasistencia vs. tamaño de la submuestra por
fig, ax = plt.subplots(figsize=(9, 6))
sns.scatterplot(data=tab_dpto.reset_index(), x='n_muestral', y='tasa_%', s=9)
for _, fila in tab_dpto.reset_index().iterrows():
    ax.annotate(fila['departamento'], (fila['n_muestral'], fila['tasa_%']),
                xytext=(4, 4), textcoords='offset points')
ax.axhline(tasa_ponderada(final, 'no_asiste'), color='black', ls='--', lw=1,
ax.set_title('G8 · Tasa de inasistencia por departamento frente al tamaño de
ax.set_xlabel('Casos muestrales en el departamento (n)'); ax.set_ylabel('Tas
plt.tight_layout(); plt.savefig(DIR_FIG / 'G8_dispersion_n_tasa.png'); plt.s
```



En el pooled, Itapúa y San Pedro están altos con n grande (2.144 y 1.699). Central tiene el n más grande (3.779) y tasa baja (4,3 %). Ñeembucú queda en 618 casos (4,5 %). Lo nuevo: el máximo de 2025 (Canindeyú) no es un departamento minúsculo (n = 314 ese año; 1.367 en el pooled). En Fase 2 no tiramos Itapúa/San Pedro ni Canindeyú como ruido; sí Ñeembucú 2025 (n = 153).

5.2. Patrones y anomalías identificados

N.º	Qué vimos	Dónde	Qué hacemos con eso
P1	Rural más que duplica a urbana los cuatro años (pooled 11,4 % vs 4,9 %; 2025: 10,4 % vs 4,4 %). La brecha se achica, no se cierra.	G1	H1 se mantiene.
P2	A los 12 años ~1,1 %; a los 17 ~18,5 % (en 2025: 0,7 % y 16,5 %). La escalera por edad no se rompe.	G3	H4 se mantiene.
P3	En el pooled, recursos / no quiere / familia ~69 %. En 2025 el 1.º pasa a ser "no quiere estudiar" (27 %) y "sin recursos" cae a 17 %. "No hay institución cerca" sigue casi solo rural.	G5, G6	H2 se mantiene (zona x motivo). Hay que testear también si el mix de motivos cambió en 2025 (H6).
P4	Pooled: Itapúa, San Pedro y Canindeyú ~11,6–11,9 %; Capital 2,1 %. En 2025 el	G4, G8	H3 se mantiene. No tratar el ranking 2022–24 como si

N.º	Qué vimos	Dónde	Qué hacemos con eso
	máximo es Canindeyú; Itapúa/San Pedro bajan.		fuera 2025.
A1	Ñeembucú pooled n = 618; en 2025 n = 153. Boquerón y Alto Paraguay siguen sin aparecer.	G8; Etapa 2.6	Más duda en Ñeembucú. El Chaco sigue fuera.

5.3. Hipótesis preliminares para la Fase 2

Cada hipótesis sale de lo observado arriba, ahora con 2022–2025. La dirección de H1–H5 **no cambió** al sumar 2025; lo que sí cambió es el mix de motivos y el ranking departamental de un año. Por eso se agrega H6.

N.º	Hipótesis (lenguaje natural)	Evidencia que la motiva	Prueba prevista	Familia	Tamaño de efecto
H1	La tasa de inasistencia es mayor en zona rural que en zona urbana (también en 2025).	G1	Prueba z de proporciones (o chi-cuadrado 2×2) sobre el n muestral	Dos proporciones	h de Cohen o diferencia de proporciones con IC
H2	Zona y motivo declarado (agrupado: económico, familiar, oferta, personal) no son independientes.	G5, G6	Chi-cuadrado de independencia (Fisher si hay celdas chicas)	Categórica × categórica	V de Cramér
H3	La tasa de inasistencia difiere entre departamentos.	G4	Chi-cuadrado (departamento × asiste/no asiste) o Kruskal-Wallis	Tres o más grupos	eta cuadrado o V de Cramér
H4	La tasa de inasistencia aumenta con la edad entre 12 y 17 años.	G3	rho de Spearman o logística simple edad → no_asiste	Asociación ordinal	rho o razón de momios
H5	La diferencia urbano/rural sigue ahí al controlar departamento, edad y sexo.	G1, G4; Canindeyú/Itapúa son más rurales	Logística múltiple: no_asiste ~ zona + departamento + edad + sexo	Efecto controlando otras	OR por variable
H6	El mix de motivos en 2025 no es el mismo que en	G5, G6; P3	Chi-cuadrado período (2022–24 vs 2025) ×	Categórica × categórica	V de Cramér

N.º	Hipótesis (lenguaje natural)	Evidencia que la motiva	Prueba prevista	Familia	Tamaño de efecto
	2022–2024 (en 2025 pesa más "no quiere estudiar" y menos "sin recursos").		motivo agrupado		

Cobertura de familias: H1 (dos proporciones) · H2 y H6 (asociación categórica) · H3 (tres o más grupos) · H4 (ordinal) · H5 (regresión múltiple) → más de tres familias, como pide el enunciado.

Qué 2025 no cambió: H1, H4 y la ausencia del Chaco. **Qué 2025 sí obliga a mirar aparte:** H6 (motivos) y el detalle de H3 (Canindeyú vs Itapúa/San Pedro según se poolée o se corte el último año).

Previsiones para la Fase 2

- $\alpha = 0,05$, declarado **antes** de correr las pruebas.
- Benjamini-Hochberg sobre H1–H4 y H6 (H5 es el modelo de control, se reporta aparte).
- Decidir con el docente: n muestral vs pesos replicados.
- Confusor principal: zona y departamento (H5). Segundo tema: 2025 puede ser un año distinto en motivos, no solo "más muestra" (H6).

6. Conclusión de la Fase 1

6.1. Principales resultados obtenidos

El panel son 24.316 personas de 12 a 17 años en las EPHC 2022–2025 (unas 2,46 millones ponderadas). La tasa nacional es 7,4 % y sigue bajando: 8,5 % (2022) → 7,4 % (2024) → 6,3 % (2025).

La brecha de zona no se da vuelta. Pooled: 11,4 % rural vs 4,9 % urbana. En 2025: 10,4 % vs 4,4 %. Sigue más del doble, con la mejora concentrada en el campo (G1).

En el mapa del **pooled**, Itapúa, San Pedro y Canindeyú quedan ~11,6–11,9 % y Capital en 2,1 % (G4). Eso no es la foto de 2025: ese año el máximo es Canindeyú (11,7 %) e Itapúa/San Pedro bajan a ~9 %; Misiones y Paraguarí suben. Ñeembucú pooled n = 618; en 2025 n = 153.

Por edad, 1,1 % a los 12 y 18,5 % a los 17 (G3). Varones 8,4 %, mujeres 6,5 %. De los que asisten, ~93 % oficial en el campo y ~75 % en la ciudad (G7).

Motivos: hay que separar pooled y 2025 (G5, G6). En 2022–2025 juntos mandan sin recursos (25,3 %), no quiere estudiar (23,2 %) y familia (20,4 %). En **solo 2025** el 1.º es no quiere estudiar (27,1 %) y sin recursos cae a 16,9 %. “No hay institución cerca” sigue siendo casi solo rural (10,6 % vs 0,6 % en el pooled; 7,8 % vs 0 % en 2025).

6.2. Respuesta parcial a la pregunta de investigación

Con lo descriptivo, zona y departamento se asocian con la inasistencia, con magnitud grande, y 2025 **no deshace** eso. Los hogares no dan un único motivo: plata, no querer seguir y familia. La oferta (escuela lejos) es un tema del campo. Lo que 2025 agrega es que **el peso de esos motivos no es estable**: en el último año gana “no quiere estudiar”, sobre todo en ciudad, y el ranking departamental del pooled no copia el de 2025.

No cerrado: si las diferencias aguantan un test (H1–H4, H6), si “rural” es en realidad “departamento X” (H5), y si se puede anticipar el riesgo individual (Fase 3). No hay causalidad: no hay colegio identificado ni panel de las mismas personas.

6.3. Limitaciones detectadas en los datos

Boquerón y Alto Paraguay siguen fuera (tampoco en 2025). Ñeembucú 2025 es especialmente fino ($n = 153$). En 2025 el peso se llama **FACTOR** y viene más redondeado que **FEX.2022**; se unificó al cargar, pero no es el mismo formato de decimal. El motivo lo declara el hogar; que en 2025 suba “no quiere estudiar” puede ser cambio real o de cómo se responde. 2022–2025 no es un panel. El FEX acá pondera tasas, no errores estándar.

6.4. Decisiones que condicionan las fases siguientes

Universo 12–17, objetivo **no_asiste**. Descriptivos ponderados. 2025 entra al mismo panel, con **FACTOR** → **FEX.2022**. No imputar motivo. Fase 3: sin establecimiento; predictores zona, departamento, edad, sexo. Si se usa año de encuesta como feature, 2025 puede estar marcando un régimen distinto de motivos (H6), no solo un dummy más.

6.5. Hipótesis que se llevan a la Fase 2

1. **H1** — rural > urbana. Lo más estable, también en 2025.
2. **H4** — sube con la edad. Igual de estable.
3. **H3** — hay diferencias entre departamentos; el *quién está peor* depende de si se poolée o se mire 2025.
4. **H2** — zona × motivo agrupado no independientes.
5. **H6** — el mix de motivos 2025 ≠ 2022–2024. Es lo que el año nuevo obliga a testear.
6. **H5** — la brecha de zona sobrevive al controlar departamento, edad y sexo.

7. Declaración de uso de asistentes de IA

Requerido por la sección 11 del enunciado.

Tarea	¿Se usó IA?	Detalle
Definición de la pregunta y de los objetivos	Parcial	El grupo definió el recorte EPHC (12–17, zona/departamento/motivo). Se usó asistencia para redactar y ordenar objetivos.
Estructura del notebook y del informe	Sí	Organización por etapas, plantilla de tablas y esqueleto del informe.
Escritura y depuración de código	Sí	Carga con <code>decimal=' '</code> , ponderación, gráficos G1–G8, bitácora y exportación. El grupo ejecutó y verificó las salidas.
Selección de pruebas y decisiones metodológicas	Parcial	Conservar el FEX, no imputar motivos y las cinco familias de H1–H5 se discutieron con asistencia y se retuvieron porque calzan con lo observado.
Interpretación de resultados y conclusiones	Sí	Las interpretaciones G1–G8, los patrones P1–P4 y la conclusión se redactaron a partir de las cifras del notebook ejecutado. El grupo es responsable de su contenido.
Redacción del informe	Sí	Informe de Fase 1 y documento de comprensión del problema.

El grupo declara haber **verificado y comprendido** todo el código y todo el texto incorporado, y estar en condiciones de responder sobre cualquier línea del trabajo durante la presentación final.

8. Matriz de contribución

Tarea	Matías Morínigo	César Vielman	Iván Paredes
Comprensión del problema y pregunta	●	●	●
Descarga y organización de microdatos			●
Limpieza, código y reproducibilidad	●	●	●
Análisis exploratorio e interpretaciones	●	●	●
Informe, PDF y entrega	●	●	●

```
In [32]: # =====
# Verificación automática de los entregables de la Fase 1
# =====
chequeos = [
    ('1 · Documento de comprensión del problema (PDF 2–3 pp.)', (RAIZ/'output'
    ('2 · Informe de la Fase 1 (PDF ≤ 20 pp.)', (RAIZ/'output'
    ('3 · Notebook ejecutado de principio a fin sin errores', True),
    ('3b · Exportación HTML del notebook', any(RAIZ.rglob
    ('4 · Diccionario de datos original', (DIR_TAB/'di
    ('4b · Diccionario de datos final', (DIR_TAB/'di
    ('5 · Dataset limpio', any(DIR_PROG
    ('6 · README de reproducción', (RAIZ/'README
    ('6b · Archivo de dependencias', (RAIZ/'requi
    (' · Bitácora de limpieza', (DIR_TAB/'bi
    (' · Ocho visualizaciones generadas', len(list(DIF
    (' · Serie temporal 2022–2025 incluida', (DIR_TAB/'se
]
for nombre, ok in chequeos:
    print(f'{"✅" if ok else "❌"} {nombre}')
pend = [n for n, ok in chequeos if not ok]
print(f'\n{len(chequeos)-len(pend)}/{len(chequeos)} listos.')
if pend:
    print('Pendientes (dependen del grupo, no del código):')
    for p in pend:
        print('  •', p)
```

- ✅ 1 · Documento de comprensión del problema (PDF 2–3 pp.)
- ✅ 2 · Informe de la Fase 1 (PDF ≤ 20 pp.)
- ✅ 3 · Notebook ejecutado de principio a fin sin errores
- ✅ 3b · Exportación HTML del notebook
- ✅ 4 · Diccionario de datos original
- ✅ 4b · Diccionario de datos final
- ✅ 5 · Dataset limpio
- ✅ 6 · README de reproducción
- ✅ 6b · Archivo de dependencias
- ✅ · Bitácora de limpieza
- ✅ · Ocho visualizaciones generadas
- ✅ · Serie temporal 2022–2025 incluida

12/12 listos.