

Inasistencia escolar en la adolescencia paraguaya

Magnitud, motivos declarados y brechas territoriales · EPHC 2022–2024

Integrantes: Matías Morínigo · César Vielman · Iván Paredes

Asignatura: Data Science · Entrega: 15 de septiembre de 2026

Fuente: DGEEC, Encuesta Permanente de Hogares Continua (REG02 anual)

1. Comprensión del problema y pregunta

El problema de decisión es cómo priorizar políticas de retención escolar en el tramo 12–17 años. La matrícula del MEC no registra el motivo de la no asistencia; la EPHC sí, porque pregunta al hogar si el adolescente asiste (ED08) y por qué no (ED10). Por eso este proyecto cambió de fuente: no hay variable de abandono en los abiertos del MEC. El costo es metodológico: unidad de análisis = persona en un hogar, y todo estadístico descriptivo va ponderado por el factor de expansión (FEX).

¿En qué medida la zona de residencia (urbana/rural) y el departamento se asocian con la tasa de inasistencia escolar de los adolescentes de 12 a 17 años en Paraguay, y qué motivos declaran los hogares para explicar esa inasistencia, entre 2022 y 2024?

Objetivo general: analizar esa asociación y caracterizar los motivos. En esta fase se cumplen OE1 (construir el panel) y OE2 (describir tasas y motivos). OE3 (contrastes) queda para Fase 2 y OE4 (clasificación de riesgo) para Fase 3.

2. Datos, unidad y calidad

Ítem	Valor
Archivos	REG02_EPHC_ANUAL_2022/2023/2024.csv (separador ; / decimal ,)
Filas crudas	61.912 + 58.005 + 57.744 = 177.661 personas, todas las edades
Universo analizado	18.558 personas de 12–17 años (población ponderada: 1.846.521)
No asistentes (muestra)	1.504; 100 % con motivo ED10 válido
Unidad	Persona dentro de un hogar, en un año (corte transversal repetido, no panel)
Clave empírica	UPM + NVIVI + NHOGA + L02 + año: 0 duplicados
Cobertura	16 departamentos. Ausentes: Boquerón y Alto Paraguay (Chaco)
Descarga	Iván Paredes · 12 de septiembre de 2026 · microdatos públicos DGEEC

El único punto de fricción de calidad fue de formato: sin decimal=',' el FEX se lee como texto y las “sumas” concatenan cadenas. Se verificó dtype float64 al cargar. Los blancos de ED08/ED09/ED10 en el archivo crudo no son faltantes: son personas fuera del universo de la pregunta educativa; se resuelven al filtrar edad 12–17. Los pesos muestrales extremos se conservaron (son diseño, no error).

3. Limpieza (bitácora resumida)

1. Renombre a nombres de trabajo (edad, zona, motivo_inasistencia, factor_expansion, ...).
2. Decodificación de códigos DGEEC a etiquetas (zona, sexo, departamento, sector, motivo).
3. Filtro a 12–17 años (177.661 → 18.558).
4. Derivadas: `asiste_actualmente` / `no_asiste` colapsando ED08=19.
5. Sin imputación de motivo ni de sector: el 91,6 % de nulos en motivo es estructural (quien asiste).

Dataset limpio: `data/processed/dataset_fase1.parquet`.

4. Resultados descriptivos

4.1 Universo y univariado

Cada edad de 12 a 17 pesa entre 16,2 % y 17,3 % (media 14,5). No se ve un hueco raro. El 58,5 % de la población representada es urbana y el 41,5 % rural; el sexo sale ~50/50. Cada año aporta alrededor de un tercio del peso. En 2024 hay menos casos de 17 años, pero el perfil agregado no se desarma.




Gráfico 2. Distribución ponderada de la edad en el universo 12–17.

4.2 La tasa y la brecha de zona

Tasa nacional ponderada: **7,8 %** (8,5 % en 2022, 7,5 % en 2023, 7,4 % en 2024). Pooled rural **11,7 %** vs. urbana **5,1 %** (más del doble). Varones 8,8 %, mujeres 6,8 %.




Gráfico 1. Tasa de inasistencia 12–17 años por zona, 2022–2024 (ponderada).

G1. Rural queda arriba los tres años: 12,8 % vs 5,2 % en 2022, 10,8 % vs 5,1 % en 2024. La distancia se achica (7,6 → 5,7 puntos) porque baja el campo, no porque suba la ciudad. Aun así, en 2024 sigue siendo más del doble.

4.3 Edad y asistencia




Gráfico 3. Edad según asiste / no asiste.

G3. Los que no asisten son más grandes (15,8 vs 14,4 años). La tasa va de 1,3 % a los 12 a 19,1 % a los 17. Se concentra cuando toca media, no parejo en todo el rango.

4.4 Departamentos




Gráfico 4. Tasa de inasistencia por departamento (media nacional 7,8 %).

G4. Itapúa 12,8 % y San Pedro 12,6 % están peor; Capital 1,8 % y Paraguari 3,7 % mejor (media nacional 7,8 %). El departamento con menos casos es Ñeembucú (465). Capital tiene 1.086, así que el 1,8 % no sale de cuatro personas.




Gráfico 8. Tasa departamental frente al n muestral.

G8. Las tasas altas no son las de muestra chica: Itapúa y San Pedro tienen n grande (1.637 y 1.310). Central, con más casos (2.829), está entre las más bajas. Ñeembucú (465) sí hay que leerlo más corto. En Fase 2 no tiramos Itapúa/San Pedro como ruido.

4.5 Motivos declarados




Gráfico 6. Ranking nacional de motivos de inasistencia.

G6. Tres respuestas se llevan la mitad larga: no hay recursos (27,6 %), no quiere estudiar (22,2 %) y motivos familiares (20,4 %). Después, trabajar (10 %) y no haber institución cerca (7,3 %). No es un solo tipo de problema.




Gráfico 5. Motivo declarado según zona (% dentro de cada zona).

G5. “Sin recursos” es el n°1 en el campo y en la ciudad, casi igual (~27,5 %). Donde se parten es la oferta: no hay institución cerca es 11,2 % rural y 0,8 % urbana. En la ciudad suben “no quiere estudiar” (25,1 % vs 20,4 %) y tener que trabajar (11,8 % vs 8,9 %). El motivo económico es común; la falta de escuela cerca es un tema del campo.

4.6 Sector de quienes asisten




Gráfico 7. Sector educativo entre quienes asisten, por zona.

G7. De los que asisten, en el campo el 93 % está en oficial (privado + subvencionado ~7 %). En la ciudad el oficial baja a 75 % y hay un 25 % no estatal. Si en el pueblo no hay colegio cerca, tampoco hay uno privado al lado.

5. Patrones, hipótesis y límites

#	Patrón	Evidencia
P1	La tasa rural más que duplica a la urbana los tres años; la brecha se estrecha por caída rural.	G1
P2	Inasistencia monótona en la edad: 1,3 % (12) → 19,1 % (17).	G3
P3	Tres motivos concentran ~70 %; la falta de institución es casi solo rural.	G5, G6
P4	Itapúa y San Pedro lideran con n grande; Capital es el mínimo con n = 1.086.	G4, G8
A1	Ñeembucú (n = 465) es más impreciso. Boquerón y Alto Paraguay no están en la muestra.	G8, Etapa 2.6

H1 tasa rural > urbana (dos proporciones). **H4** inasistencia crece con la edad (Spearman / logística). **H3** diferencias entre departamentos. **H2** zona × motivo agrupado no independientes. **H5** la brecha de zona sobrevive al controlar departamento, edad y sexo. $\alpha = 0,05$; Benjamini-Hochberg sobre H1–H4. Pendiente con el docente: contrastes sobre n muestral vs. replicación de pesos. Variable objetivo de Fase 3: no_asiste.

Límites: sin variables de establecimiento; no es panel; motivo autorreportado; FEX sin corrección de diseño en esta fase; chi-cuadrado exploratorio sobre población expandida infla el p-valor (V de Cramér $zonaxsector = 0,23$ se usa solo como tamaño de asociación); resultados no extensibles al Chaco.

6. Conclusión de la Fase 1

Con lo descriptivo, zona y departamento se mueven con la inasistencia, y se mueven bastante: más del doble rural vs urbana, y unos 11 puntos entre Capital e Itapúa. Los hogares hablan sobre todo de plata, de no querer seguir y de la familia. La falta de escuela cerca aparece en el campo y casi no aparece en la ciudad.

Esta fase no cierra si eso aguanta un test (Fase 2), si “rural” no es en realidad un departamento en particular (H5), ni si se puede anticipar el riesgo de una persona (Fase 3). Tampoco decimos causalidad: la encuesta no identifica el colegio ni sigue a los mismos pibes.

Queda fijo: universo 12–17, objetivo `no_asiste`, descriptivos ponderados, sin imputar motivo y sin predictores de establecimiento en Fase 3. A Fase 2 llevamos H1 (zona), H4 (edad), H3 (departamento), H2 (motivo x zona) y H5 (zona controlando el resto).

7. Reproducibilidad y uso de IA

Notebook: `notebooks/Fase1_DataScience_EPHC.ipynb`. Dependencias: `requirements.txt`. Semilla 42. Figuras G1–G8 en `output/figuras/`.

Se usó asistencia de IA para estructura, código, interpretaciones y redacción de este informe. El grupo verificó las cifras contra las salidas del notebook y declara poder responder por cada línea en la presentación. Detalle por tarea en la sección 7 del notebook.